TEK-UP

Département : Data Science & Intelligence Artificielle

Séries Temporelles

Analyse et prévision des séries horaires d'énergie en Allemagne

Thème : Analyse et prévision des séries temporelles énergétiques (ENTSO-E) — `Load`, `Wind`, `Solar` en MW, fréquence horaire, période 01/01/2015 – 30/09/2020

Réalisé par :

Ons Ben Othmen

Ibtihel Belhouchet

Encadré par :

M. Ahmed Dhouibi

Année universitaire : 2025–2026

Date : Octobre 2026

Table des matières

1 Introduction **3**
- 1.1 Contexte et thématique . . . 3
- 1.2 Problématique . . . 3
- 1.3 Objectifs . . . 3
- 1.4 Organisation du rapport . . . 3

2 Méthodologie **4**
- 2.1 Source et description des données . . . 4
- 2.2 Prétraitement et imputation . . . 4
- 2.3 Découpage chronologique . . . 5
- 2.4 Analyse exploratoire (EDA) . . . 5
- 2.5 Stationnarité et ordres d'intégration . . . 5
- 2.6 Modèles univariés : ARIMA et SARIMA . . . 5
- 2.7 Modèles multivariés : VAR, Granger, Johansen, VECM . . . 5
- 2.8 Modélisation de la volatilité : ARCH / GARCH . . . 6
- 2.9 Modèles profonds : LSTM et GRU . . . 6
- 2.10 Intervalles de prévision . . . 6
- 2.11 Modèles additionnels : Prophet et hybride SARIMA+LSTM . . . 6
- 2.12 Évaluation comparative . . . 7

3 Résultats **7**
- 3.1 Analyse exploratoire des données (EDA) . . . 7
  - 3.1.1 Statistiques descriptives . . . 7
  - 3.1.2 Évolution temporelle et vue d'ensemble . . . 7
  - 3.1.3 Profils saisonniers . . . 9
  - 3.1.4 Valeurs manquantes et valeurs atypiques . . . 13
  - 3.1.5 Stationnarité . . . 14
  - 3.1.6 Corrélogrammes ACF / PACF . . . 14
- 3.2 Socle univarié : ARIMA / SARIMA . . . 19
  - 3.2.1 Sélection des modèles . . . 19
  - 3.2.2 Diagnostics des résidus . . . 20
  - 3.2.3 Prévisions et métriques . . . 20
- 3.3 Liaisons dynamiques : VAR, Granger, Johansen, VECM . . . 26
  - 3.3.1 Sélection de l'ordre du VAR . . . 26
  - 3.3.2 Causalité de Granger . . . 27
  - 3.3.3 Cointégration de Johansen et VECM . . . 27
  - 3.3.4 Diagnostics du VAR . . . 28
  - 3.3.5 Réponse impulsionnelle et décomposition de la variance . . . 28
- 3.4 Modélisation de la volatilité : ARCH / GARCH . . . 30
  - 3.4.1 Persistance de la volatilité . . . 30
  - 3.4.2 Coefficients estimés . . . 31
  - 3.4.3 Diagnostics GARCH et volatilité conditionnelle . . . 31
- 3.5 Modèles profonds : LSTM / GRU . . . 34

4 Évaluation comparative **37**
4.1 Classement général (R vs Python vs LSTM/GRU) . . . 37
4.2 Walk-forward à un pas . . . 38
4.3 Test de Diebold–Mariano . . . 39

5 Interface interactive : dashboard Streamlit **40**
5.1 Vue d'ensemble . . . 40
5.2 Page « Figures » . . . 40
5.3 Page « Tableaux de résultats » . . . 41
5.4 Page « Diebold–Mariano » . . . 42
5.5 Page « Prévisions walk-forward » . . . 42
5.6 Page « Leaderboard » . . . 43

6 Conclusion **44**
6.1 Bilan des résultats . . . 44
6.2 Limites . . . 45
6.3 Perspectives . . . 45

7 Annexes **46**
7.1 Structure du projet et reproductibilité . . . 46
7.2 Tableaux de synthèse complémentaires . . . 46
7.3 Inventaire des figures . . . 49
7.4 Inventaire des tableaux . . . 50
7.5 Volet IA générative . . . 51

1 Introduction

1.1 Contexte et thématique

Le présent mini-projet de séries temporelles porte sur l'analyse et la prévision de trois séries horaires du système électrique allemand, mises à disposition par la plateforme de transparence **ENTSO-E** :

— `Load` : la consommation électrique nationale (charge nette) ;
— `Wind` : la production éolienne terrestre et en mer ;
— `Solar` : la production photovoltaïque.

Toutes les séries sont exprimées en **mégawatts (MW)** et couvrent la période du **1er janvier 2015** au **30 septembre 2020**, soit 50 400 observations à pas horaire, horodatées en **UTC** (ce qui élimine toute ambiguïté liée aux changements d'heure été/hiver).

Le choix de l'énergie se justifie par la richesse structurelle des données : forte saisonnalité journalière et hebdomadaire (cycles d'activité humaine pour la charge), saisonnalité annuelle et météorologique (éolien et solaire), volatilité par grappes (épisodes venteux, journées ensoleillées) et interdépendances économiques entre consommation et production renouvelable. Ce contexte autorise un spectre complet de méthodes : modèles univariés (ARIMA/SARIMA), modèles multivariés dépendant du temps (VAR/VECM), modélisation de la volatilité (GARCH) et apprentissage profond (LSTM/GRU).

1.2 Problématique

La transition énergétique allemande (*Energiewende*) fait de l'équilibre offre/demande un enjeu critique. Trois questions guident le travail :

1. Peut-on **prévoir** ces séries à court ($h = 10$ et $h = 24$ heures), moyen et très long terme ($h = 5\,040$ heures, soit environ 7 mois) ?
2. Existe-t-il des **relations dynamiques** (causalité, cointégration) entre consommation et productions renouvelables ?
3. Les **modèles profonds** (LSTM/GRU) surpassent-ils les modèles classiques, et de façon statistiquement significative ?

1.3 Objectifs

Le travail poursuit quatre objectifs, alignés sur le cahier des charges :

1. Réaliser le **socle classique en R** (sections 3.1 ARIMA/SARIMA, 3.2 VAR / causalité de Granger / VECM, 3.3 ARCH/GARCH) ;
2. **Transposer** l'intégralité de ce socle en **Python**, afin de vérifier la reproductibilité des résultats (*double implémentation*) ;
3. Étendre l'analyse aux **modèles profonds LSTM/GRU** en Python ;
4. Conduire une **évaluation comparative** rigoureuse (métriques MSE/RMSE/MAE/MAPE, walk-forward à un pas, test de **Diebold–Mariano**) et restituer l'ensemble dans un rapport scientifique avec tableaux et figures issus des scripts.

1.4 Organisation du rapport

La suite est organisée comme suit. La section 2 détaille les données, le prétraitement et l'ensemble des méthodologies. La section 3 présente les résultats empiriques (analyse

exploratoire, ARIMA/SARIMA, VAR/VECM, GARCH, LSTM/GRU). La section 4 compare les modèles. La section 6 conclut et discute les limites. Les annexes recensent l'ensemble des figures et tableaux produits.

2 Méthodologie

2.1 Source et description des données

Les données proviennent de la plateforme **ENTSO-E Transparency Platform** "ENTSO-E Transparency Platform", 2026, diffusées via le portail open-data *Open Power System Data* (fichier brut `data/raw/time_series_60min_singleindex.csv`). Après sélection des colonnes allemandes, conversion des horodatages en `DatetimeIndex` UTC, tri chronologique et dédoublonnage, le jeu analytique final est `data/processed/germany_energy_analysis`

TABLE 1 – Fiche synthétique du jeu de données.

Champ	Valeur
Thématique	Énergie / Environnement — Allemagne
Source	ENTSO-E Transparency Platform
Fréquence	Horaire (60 min), horodatage UTC
Période	2015-01-01 00 :00 → 2020-09-30 23 :00
Nombre d'observations	50 400
Trous / doublons	0
Valeurs manquantes	`Load` : 0 ; `Wind` : 74 ; `Solar` : 103
Variables retenues	`Load`, `Wind`, `Solar` (MW)

Variables retenues. `Load` est la consommation électrique nationale (variable endogène principale) ; `Wind` et `Solar` sont les productions éolienne et photovoltaïque. Le triplet consommation + deux renouvelables constitue un système multidimensionnel cohérent, justifiant le volet VAR/VECM.

Contrôles qualité. L'index horaire attendu (`date_range` de fréquence horaire) coïncide exactement avec les horodatages présents : aucun trou, aucun doublon. Les valeurs manquantes sont rares et isolées (74 pour `Wind`, 103 pour `Solar`) ; elles sont **conservées** dans le fichier analytique afin de ne pas fausser l'exploration, puis imputées juste avant la modélisation.

2.2 Prétraitement et imputation

La construction de l'objet série temporelle natif diffère légèrement entre R et Python : côté R, on utilise `ts(..., frequency = 24)` (cycle quotidien) ; côté Python, un `DataFrame` pandas à `DatetimeIndex` UTC avec fréquence déclarée `h`. L'imputation suit une approche heure-saisonnière identique entre les deux langages : médiane par heure de la journée, complétée par une interpolation linéaire (`forecast::na.interp` en R). Ce choix préserve la régularité horaire indispensable aux modèles saisonniers ($m = 24$), contrairement à une suppression de lignes qui briserait le pas de temps.

2.3 Découpage chronologique

Le découpage est **strictement chronologique** 90 % / 10 % (jamais aléatoire, pour éviter toute fuite d'information future) : 45 360 heures d'apprentissage et 5 040 heures de test. Le jeu de test débute le **5 mars 2020** et inclut donc l'entrée dans la crise sanitaire COVID-19, ce qui constitue un point d'interprétation important. Quatre horizons sont évalués : $h \in \{5, 10, 24, 5\,040\}$ heures (5 et 10 pour le court terme, 24 pour le cycle journalier, 5 040 pour la trajectoire complète sur tout le jeu de test).

2.4 Analyse exploratoire (EDA)

L'EDA comprend : (i) l'évolution temporelle des trois séries sur toute la période ; (ii) les profils moyens horaire, hebdomadaire, mensuel et annuel ; (iii) la cartographie des valeurs manquantes ; (iv) la détection d'observations atypiques (règle IQR globale et MAD roulante sur 24 h) ; (v) les corrélogrammes ACF/PACF (séries brutes et différenciées) ; (vi) une décomposition STL (tendance / saisonnalité / résidus) pour la charge.

2.5 Stationnarité et ordres d'intégration

La stationnarité est testée par le test **ADF** (H0 : racine unitaire) et le test **KPSS** (H0 : stationnarité), sur les séries brutes, en différence première ($d = 1$) et en différence saisonnière ($d = 24$). La conclusion retenue exige l'accord des deux tests.

2.6 Modèles univariés : ARIMA et SARIMA

Pour chaque série, trois candidats sont comparés par critère d'information (AIC/AICc/BIC) :

1. **SARIMA_manuel** : ARIMA$(1, 1, 1)(1, 1, 1)_{24}$, motivé par les corrélogrammes de l'EDA (rebonds à 24 et 168) ;
2. **ARIMA_auto** : `auto.arima` non saisonnier ($d = 1$) ;
3. **SARIMA_auto** : `auto.arima` saisonnier borné à $m = 24$.

Le modèle retenu est celui qui minimise l'**AICc**. Les résidus sont diagnostiqués par le test de **Ljung–Box** (autocorrélation, retard 24), le test de **Jarque–Bera** (normalité) et un test **ARCH–LM** (12 retards) implémenté manuellement. Les prévisions sont produites aux horizons $h = 5$, 10, 24 et 5 040 avec les métriques MSE, RMSE, MAE et MAPE (ce dernier calculé sans division par zéro, `Solar` étant nulle la nuit).

Intervalles de prévision. Pour le modèle retenu, les **intervalles de prévision** à 95 % sont calculés aux horizons $h = 5$, 10, 24 (c'est-à-dire dans les plages où la spécification reste valide, contrairement à $h = 5\,040$ où la bande diverge). Ils sont obtenus via `pmdarima` pour les spécifications saisonnières : le mode `low_memory` de `statsmodels`, nécessaire pour ajuster un SARIMA saisonnier sur 45 360 points sans saturer la mémoire, n'expose pas la covariance de prévision.

2.7 Modèles multivariés : VAR, Granger, Johansen, VECM

Les liaisons structurelles entre consommation et productions s'expriment à l'échelle **journalière** : les séries sont donc agrégées en moyennes quotidiennes ($\approx 2\,100$ jours). Pour chaque série univariée, le test ADF justifie la différenciation $D1$, puis :

— l'ordre p du **VAR** est sélectionné par critère d'information (AIC/HQ/SC/FPE, `lag.max`=15) ;
— la **causalité de Granger** est testée en paires pour les six relations ordonnées (H0 : X ne cause pas Y au sens de Granger) ;
— la **cointégration de Johansen** (test de trace) est menée sur les niveaux pour déterminer le rang r ; si $r \geq 1$, un **VECM** est estimé (vecteurs β normalisés et vitesses d'ajustement α) ;
— les dynamiques sont synthétisées par les **fonctions de réponse impulsionnelle** (IRF, choc `Wind`/`Solar` sur `Load`, 28 jours) et la **décomposition de la variance** (FEVD).

2.8 Modélisation de la volatilité : ARCH / GARCH

Les tests ARCH–LM ayant rejeté l'absence d'effet ARCH, la variance conditionnelle des variations journalières est modélisée par trois spécifications comparées, avec innovations de Student (queues épaisses) : **GARCH(1,1)**, **GARCH(2,1)** et **EGARCH(1,1)**. La **persistance** est définie comme la somme de tous les coefficients ARCH et GARCH pour un sGARCH (respectivement β_1 pour un eGARCH) ; la demi-vie de la volatilité est $\log(0{,}5)/\log(\text{persistance})$ lorsque la persistance est strictement comprise entre 0 et 1.

2.9 Modèles profonds : LSTM et GRU

En Python (Keras/TensorFlow), des réseaux récurrents **LSTM** et **GRU** sont entraînés séparément avec : fenêtre glissante de 168 h (= 1 semaine), normalisation *MinMax ajustée sur le seul train*, validation chronologique de 5 040 h, **couche de Dropout** ($p = 0{,}2$) entre l'état récurrent et la sortie pour limiter le surapprentissage, et prévision récursive multi-pas. Les deux architectures sont évaluées et la meilleure (sur la `val_loss`) est conservée par série ; l'évaluation est menée à un pas en *walk-forward* et sous forme de trajectoires aux horizons $h = 5/10/24/5040$.

Validation croisée temporelle (TSCV). En complément du simple hold-out, une **validation croisée à fenêtre expansive** ($k = 3$ plis) est appliquée aux réseaux : le train grandit progressivement, la validation reste toujours postérieure au train, ce qui fournit une estimation de la RMSE plus robuste et sans fuite temporelle.

2.10 Intervalles de prévision

Les intervalles à 95 % sont produits pour le modèle retenu à $h = 5$, 10, 24 (SARIMA via `pmdarima`) et pour Prophet (nativement, bande `yhat_lower`/`yhat_upper`). Les modèles profonds et l'hybride fournissent une prévision ponctuelle ; l'incertitude y est appréhendée par la dispersion des erreurs walk-forward.

2.11 Modèles additionnels : Prophet et hybride SARIMA+LSTM

Deux modèles complémentaires confrontent les approches classiques et profondes :
— **Prophet** (Meta) : décomposition automatique en tendance linéaire par morceaux, saisonnalités quotidienne / hebdomadaire / annuelle et jours fériés, robuste aux valeurs manquantes ;

— **hybride SARIMA + LSTM** : la composante *linéaire* est captée par le SARIMA retenu, dont les résidus (supposés porter la structure non linéaire) alimentent un LSTM ; la prévision hybride est la somme des deux, méthode classique d'hybridation tendance / résidu.

2.12 Évaluation comparative

Les métriques sont MSE, RMSE, MAE et MAPE. Deux protocoles sont distingués : (i) des **trajectoires** émises depuis une origine unique aux horizons $h = 5/10/24/5040$; (ii) un **walk-forward 1 pas** sur les 5 040 h de test (origine glissante), où chaque prévision n'utilise que l'information passée. Le walk-forward confronte les baselines *naïve* et *saisonnière-naïve* (24 h) au SARIMA retenu, au LSTM et au GRU.

Les comparaisons par paires utilisent le test de **Diebold–Mariano** sur les erreurs quadratiques, appliqué à **toutes les paires** de modèles d'une même série, avec correction **HLN** (Harvey–Leybourne–Newbold) et variance **HAC** (Newey–West, retard $h-1$). Enfin, un **tableau de comparaison** enrichi associe aux performances la *complexité* (nombre de paramètres), le *coût de calcul* et l'*interprétabilité* de chaque famille de modèles, comme demandé au cahier des charges.

3 Résultats

Cette section présente l'ensemble des résultats empiriques produits par les scripts R et Python. Toutes les figures sont issues de `results/figures/` et tous les tableaux de `results/tables/`.

3.1 Analyse exploratoire des données (EDA)

3.1.1 Statistiques descriptives

Le tableau 2 résume les trois séries. La charge (`Load`) est la plus stable (écart-type $\approx 10\,015$ MW, quasi-symétrique : skewness ≈ 0) et présente une kurtosis négative ($-1{,}10$), indice d'une distribution en plateau typique d'un cycle journalier régulier. `Wind` et `Solar` sont fortement asymétriques (skewness 1,14 et 1,54) et bornées à gauche (0 pour le solaire la nuit, minimum 135 MW pour l'éolien), ce qui traduit des distributions à queue droite.

TABLE 2 – Statistiques descriptives (MW) des trois séries. Source : `descriptive_statistics_py.csv`.

Variable	Moyenne	Écart-type	Min	Q1	Médiane	Q3	Max	Skew	Kurt.
`Load`	55 492	10 015	31 307	47 106	55 092	64 309	77 549	−0,01	−1,10
`Wind`	11 552	9 076	135	4 506	9 015	16 114	46 064	1,14	0,76
`Solar`	4 566	6 940	0	0	173	7 342	32 947	1,54	1,38

3.1.2 Évolution temporelle et vue d'ensemble

La figure 1 donne une vue d'ensemble des trois séries sur les 50 400 heures, complétée par les figures 2, 3 et 4. On y lit une saisonnalité annuelle nette (creux de charge en août,

pic hivernal), un profil solaire parfaitement nul la nuit, et un éolien très volatil sans cycle annuel marqué.

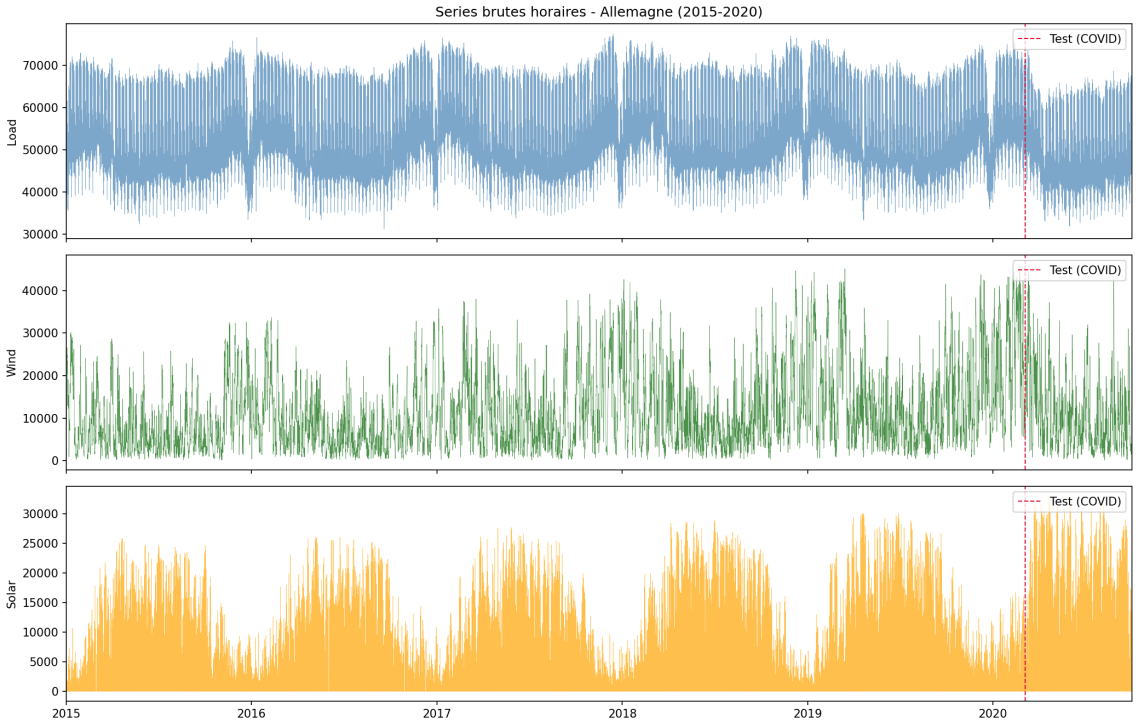


FIGURE 1 – Vue d'ensemble des trois séries horaires (2015–2020).

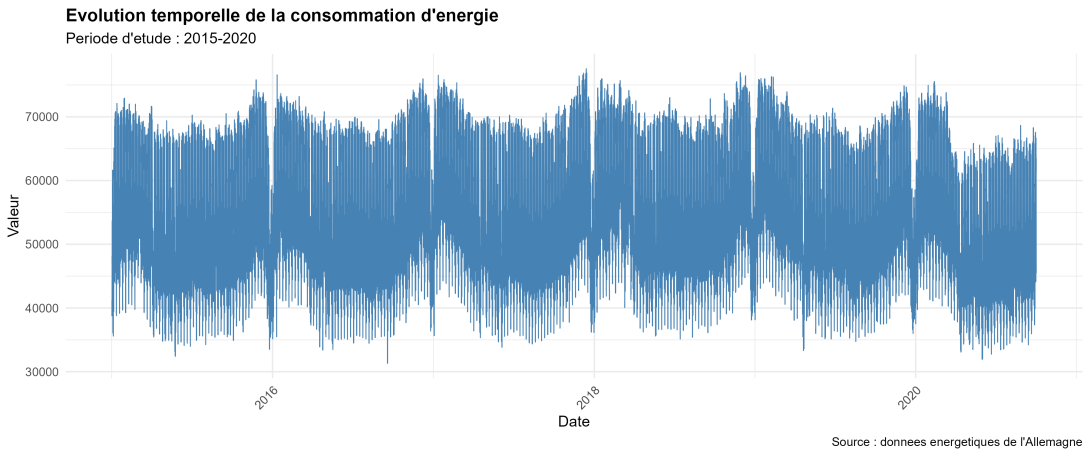


FIGURE 2 – Évolution temporelle de la consommation (`Load`).

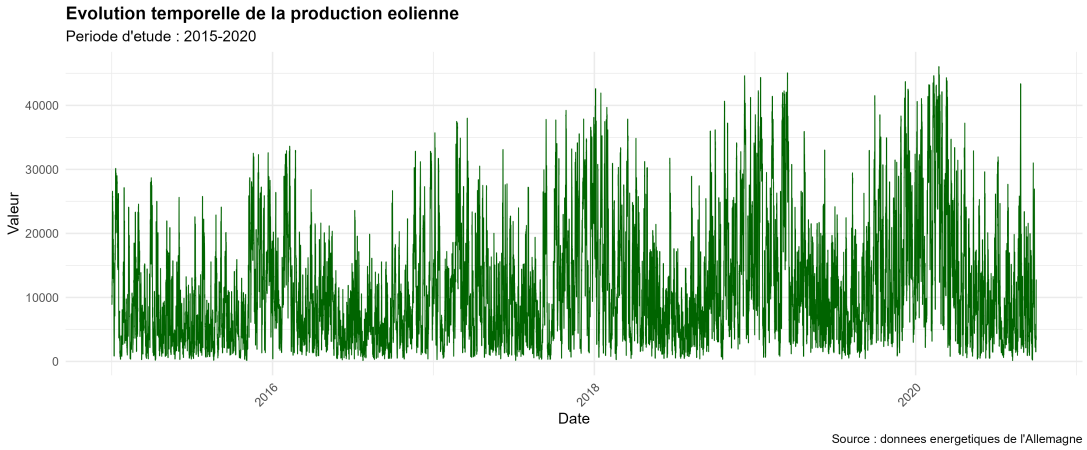


FIGURE 3 – Évolution temporelle de la production éolienne (`Wind`).

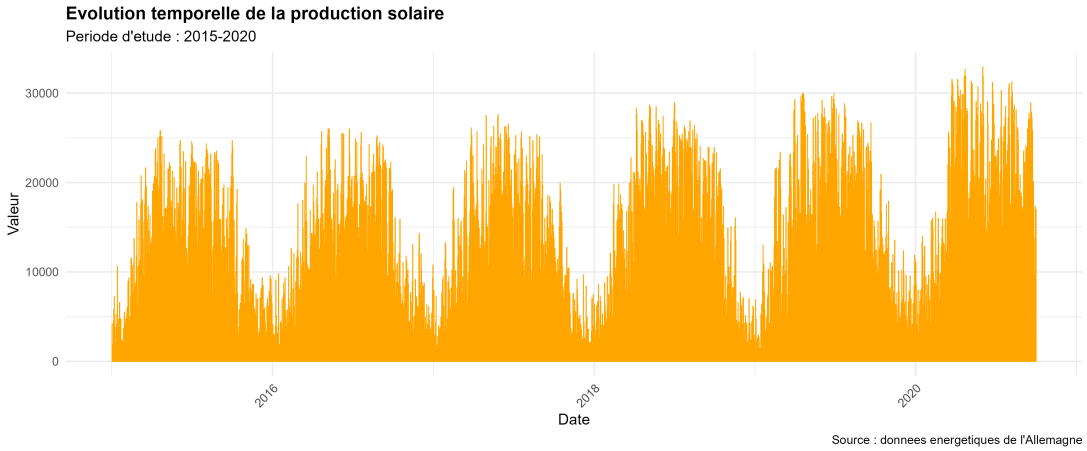


FIGURE 4 – Évolution temporelle de la production solaire (`Solar`).

3.1.3 Profils saisonniers

Le profil horaire (figure 5) montre un double pic de charge ($\approx$ 9 h et 19 h) et un solaire en cloche centré sur 11–12 h. Le profil hebdomadaire (figure 6) révèle une baisse de la charge le week-end, alors que la production renouvelable est indépendante du jour de la semaine. Le profil mensuel (figure 7) oppose un éolien hivernal (max en décembre) à un solaire estival (max en juin–juillet). L'évolution annuelle (figure 8) permet enfin de suivre ces tendances de fond.

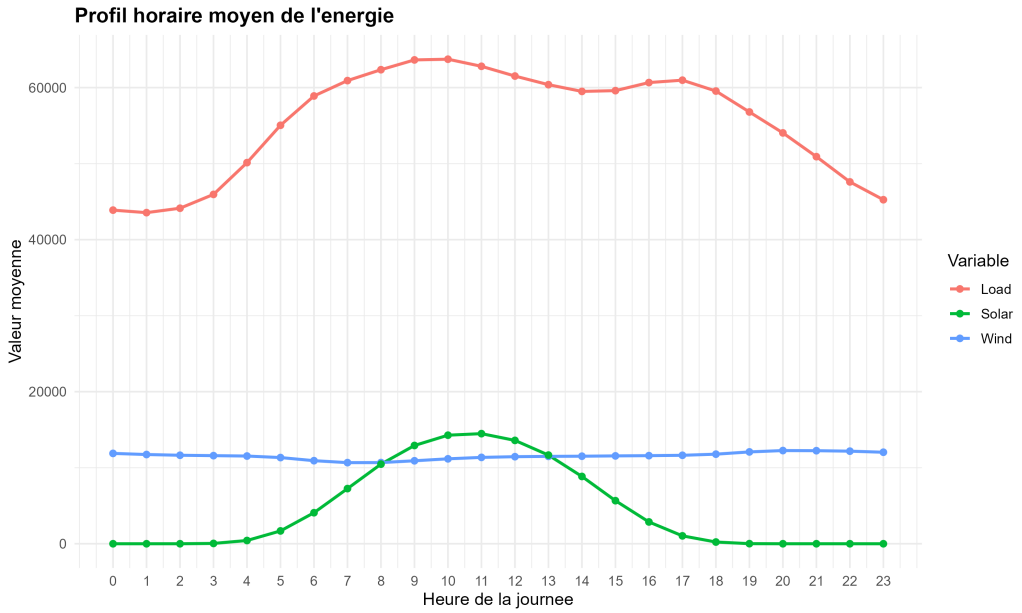


FIGURE 5 – Profil horaire moyen des trois séries.

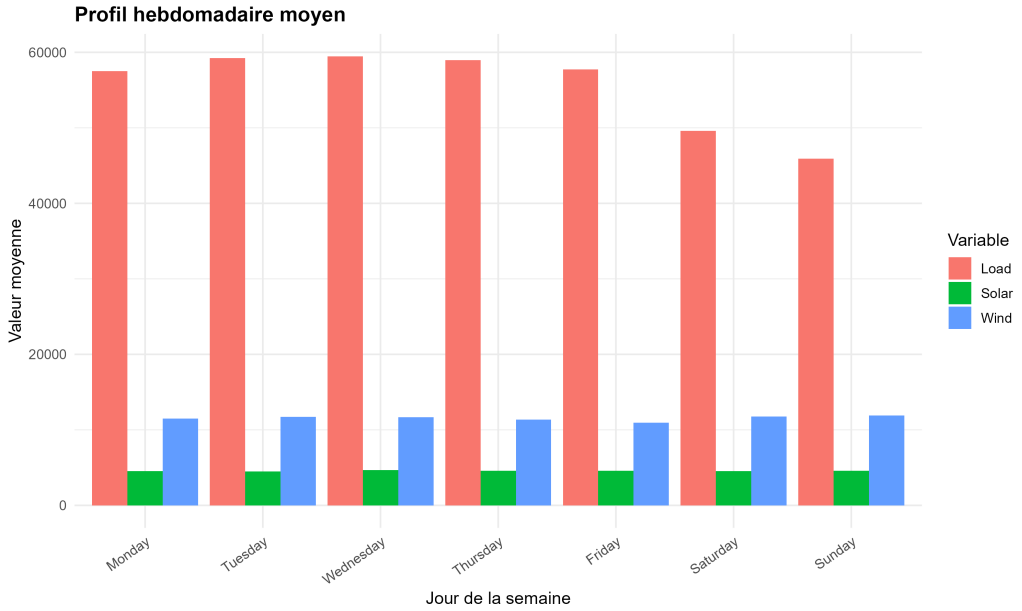


FIGURE 6 – Profil hebdomadaire moyen.

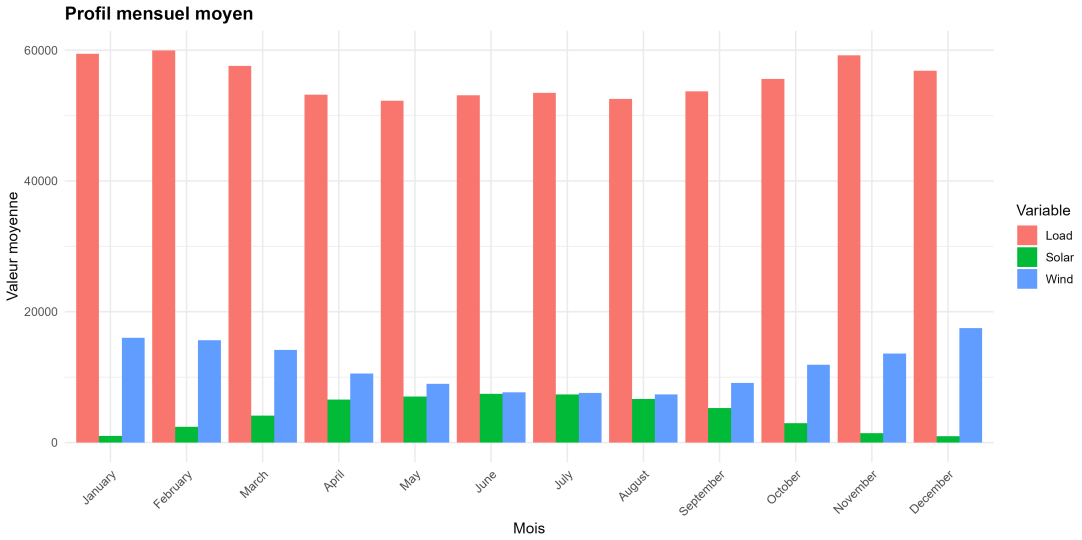


FIGURE 7 – Profil mensuel moyen.

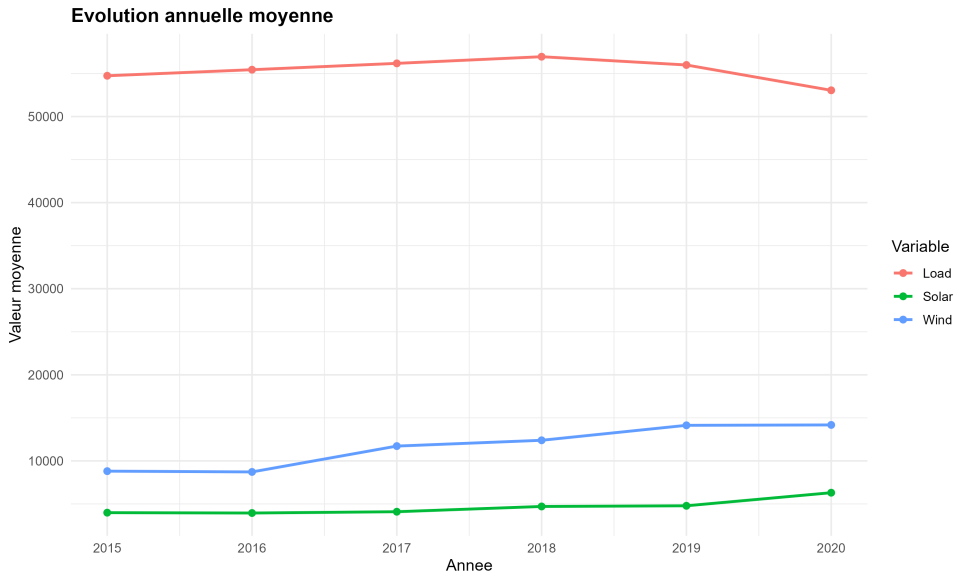


FIGURE 8 – Évolution annuelle moyenne.

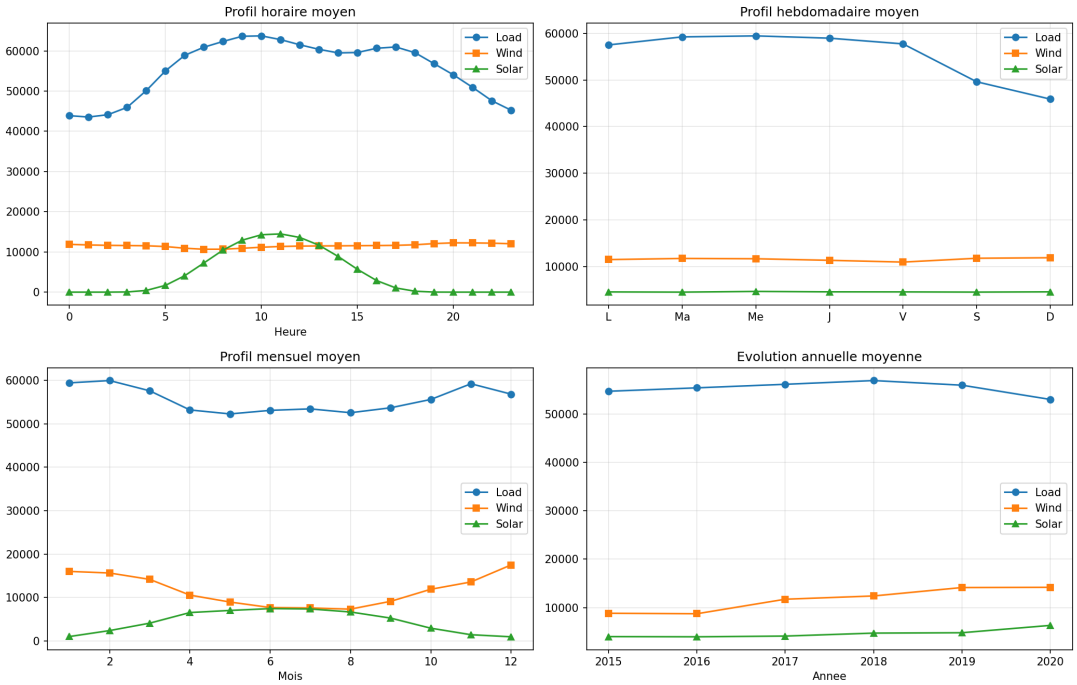


FIGURE 9 – Profils saisonniers (calcul Python).

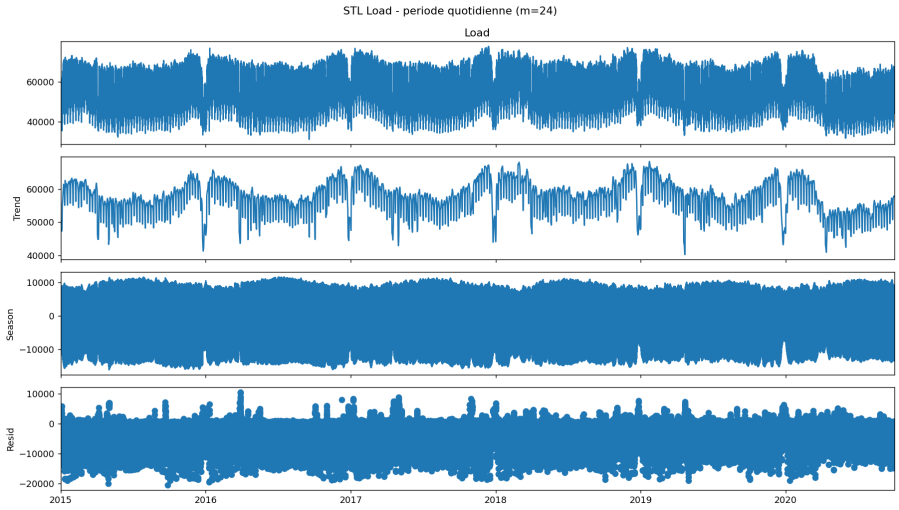


FIGURE 10 – Décomposition STL de la charge (cycle journalier).

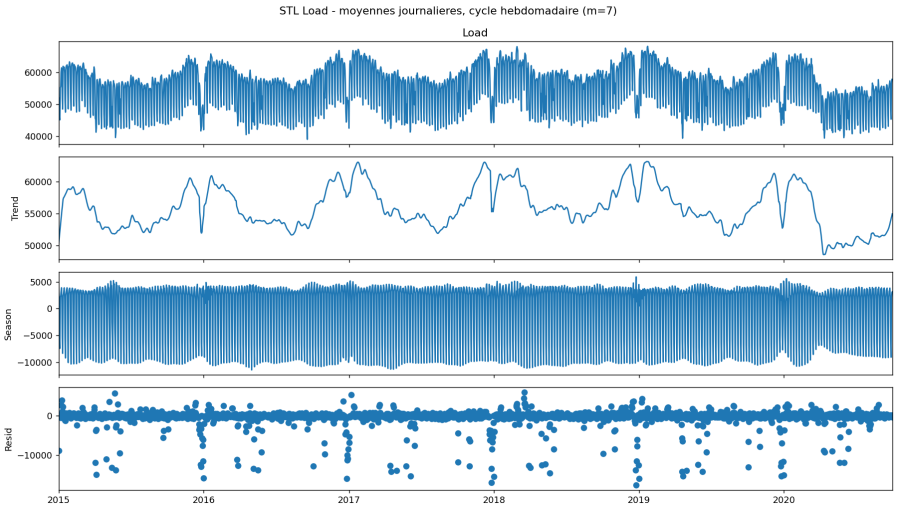


FIGURE 11 – Décomposition STL de la charge (cycle hebdomadaire).

3.1.4 Valeurs manquantes et valeurs atypiques

Les valeurs manquantes (figure 12 et 13) sont rares et éparses. Le tableau 3 montre que la règle IQR globale ne détecte aucun point, tandis que la MAD roulante sur 24 h identifie 761 points atypiques (1,51 %) — principalement des épisodes éoliens extrêmes, illustrés par la figure 14.

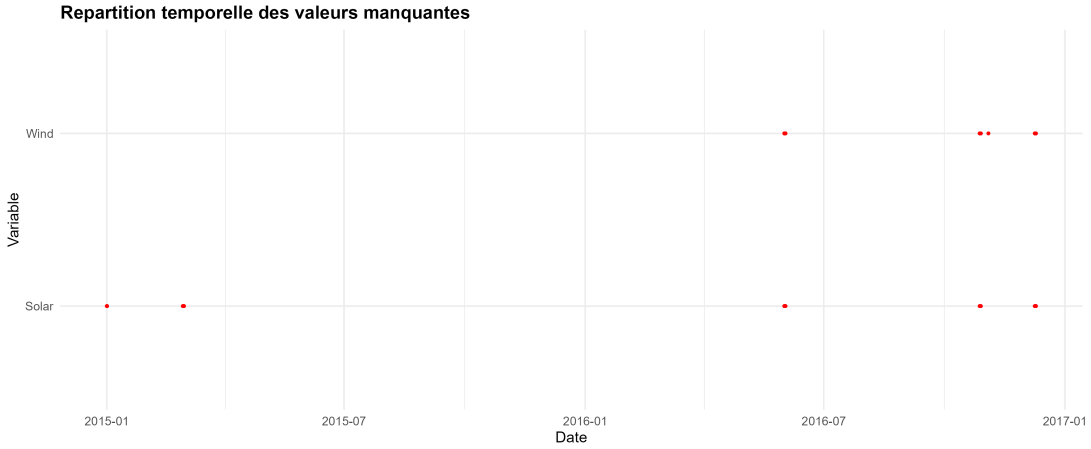


FIGURE 12 – Répartition temporelle des valeurs manquantes (R).

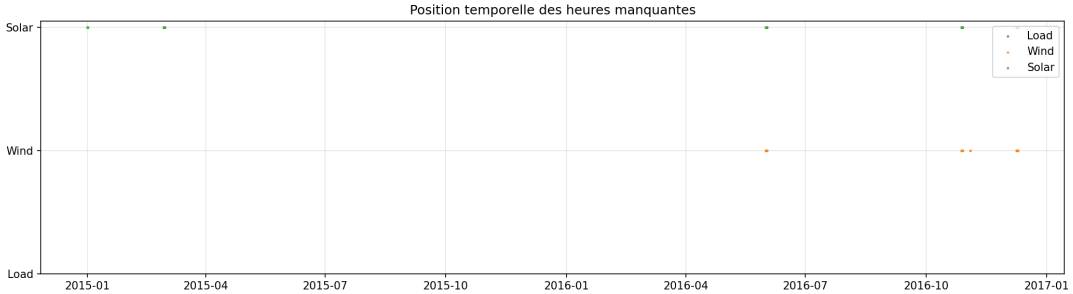


FIGURE 13 – Répartition temporelle des valeurs manquantes (Python).

TABLE 3 – Détection d'observations atypiques. Source : `outliers_summary.csv`.

Méthode	Nombre d'outliers	Part (%)
IQR global	0	0,00
MAD roulante 24 h	761	1,51

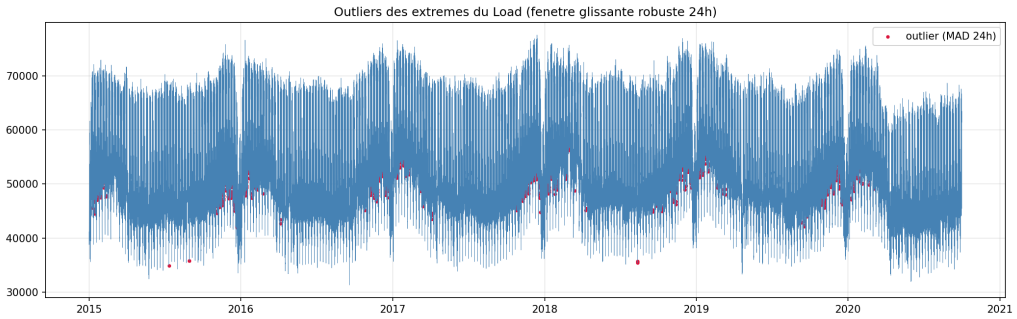


FIGURE 14 – Détection d'outliers sur la charge (MAD roulante).

3.1.5 Stationnarité

Le tableau 4 (résultat R) montre que les séries brutes sont jugées non stationnaires (ADF rejette la racine unitaire mais KPSS rejette la stationnarité : les deux tests divergent). En différence première ($d = 1$), ADF et KPSS s'accordent : les séries sont **stationnaires**. Ceci justifie l'usage de $d = 1$ dans les modèles ARIMA et de $D1$ dans le VAR/GARCH. Les conclusions sont identiques côté Python (`stationarity_tests.csv`).

TABLE 4 – Tests de stationnarité ADF / KPSS (R). Source : `R_stationarity_tests.csv`.

Variable	Transf.	ADF stat	ADF p	KPSS stat	KPSS p	Stationnaire ?
`Load`	brute	−24,75	0,01	2,497	0,01	Non
`Load`	$d1$	−42,49	0,01	0,0007	0,10	Oui
`Wind`	brute	−18,68	0,01	17,363	0,01	Non
`Wind`	$d1$	−44,68	0,01	0,0005	0,10	Oui
`Solar`	brute	−11,69	0,01	10,792	0,01	Non
`Solar`	$d1$	−46,02	0,01	0,0004	0,10	Oui

3.1.6 Corrélogrammes ACF / PACF

Les figures 15 à 20 présentent les ACF/PACF (R puis Python). Les séries brutes affichent une décroissance lente et des rebonds marqués à 24 et 168 (saisonnalité quotidienne et hebdomadaire). Après différenciation, les autocorrélations restent significatives aux retards saisonniers, motivant la composante saisonnière $(1, 1, 1)_{24}$.

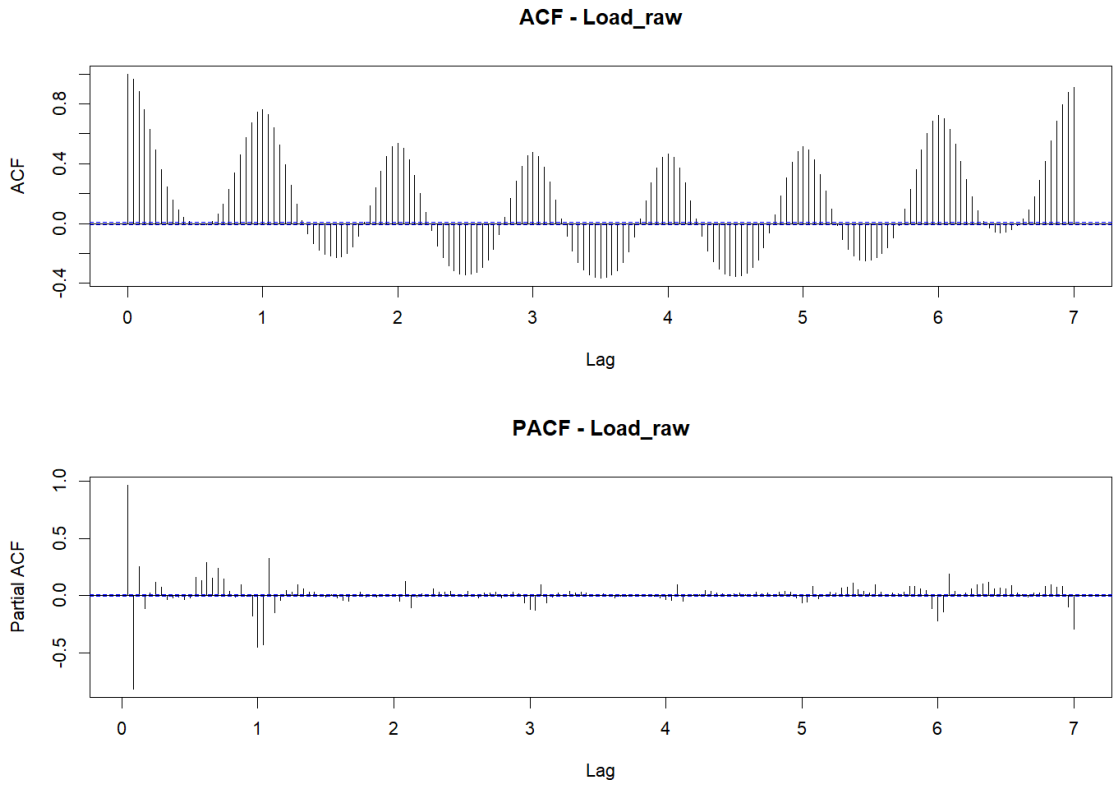


FIGURE 15 – ACF/PACF de `Load` (série brute, R).

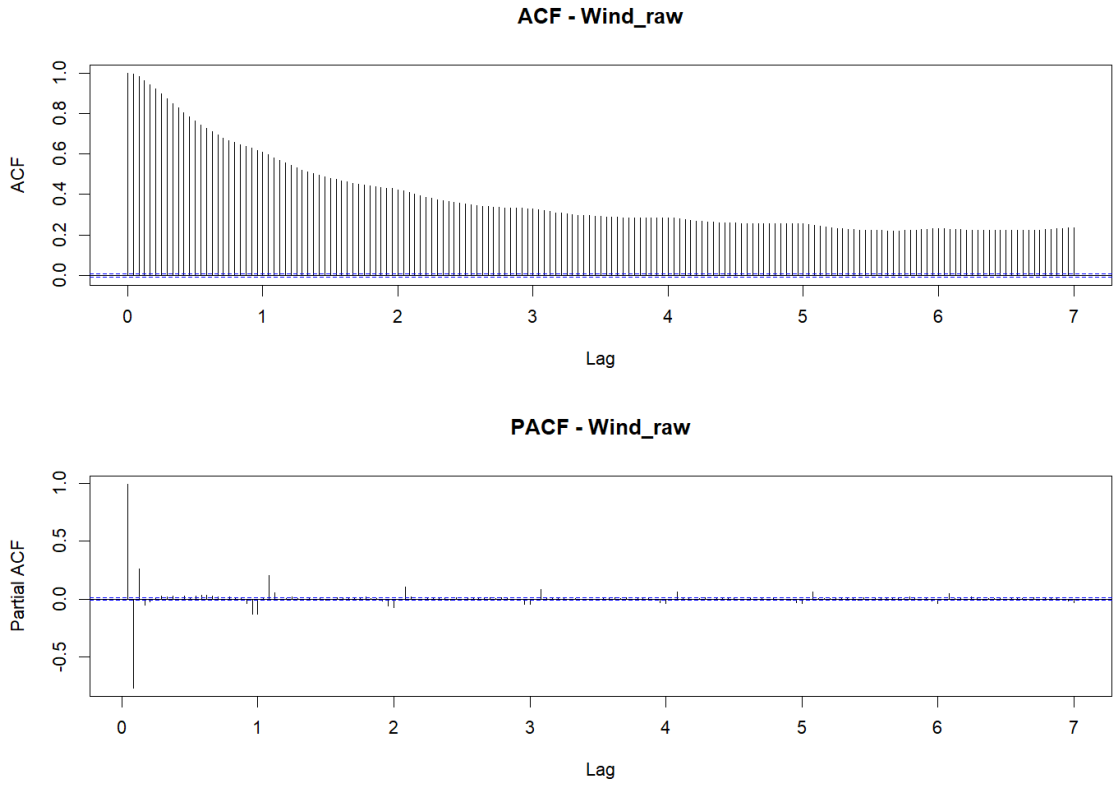


FIGURE 16 – ACF/PACF de `Wind` (série brute, R).

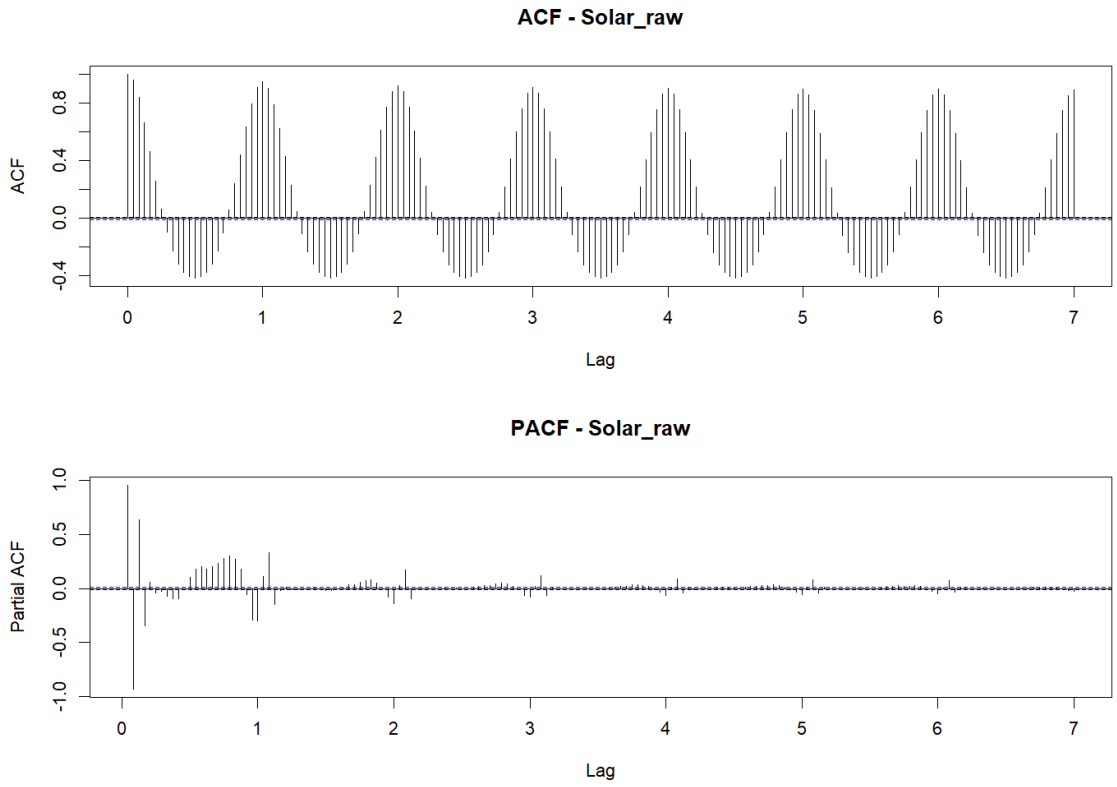


FIGURE 17 – ACF/PACF de `Solar` (série brute, R).

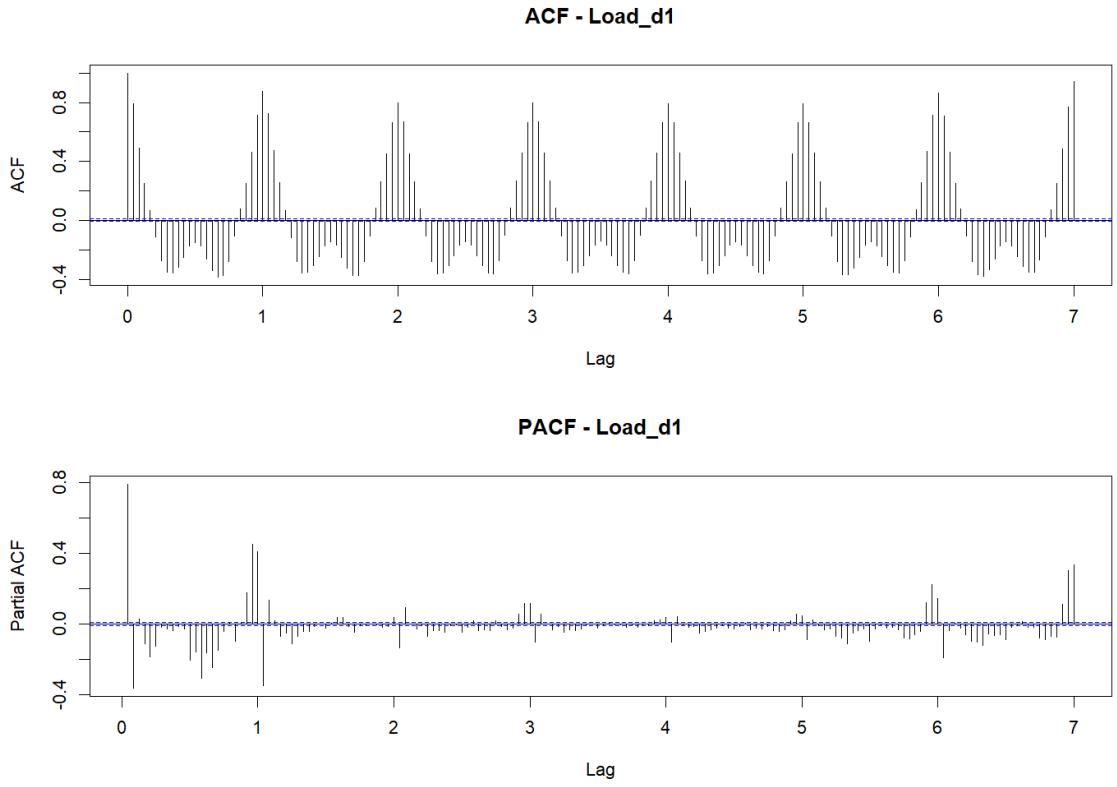


FIGURE 18 – ACF/PACF de `Load` différenciée ($d1$, R).

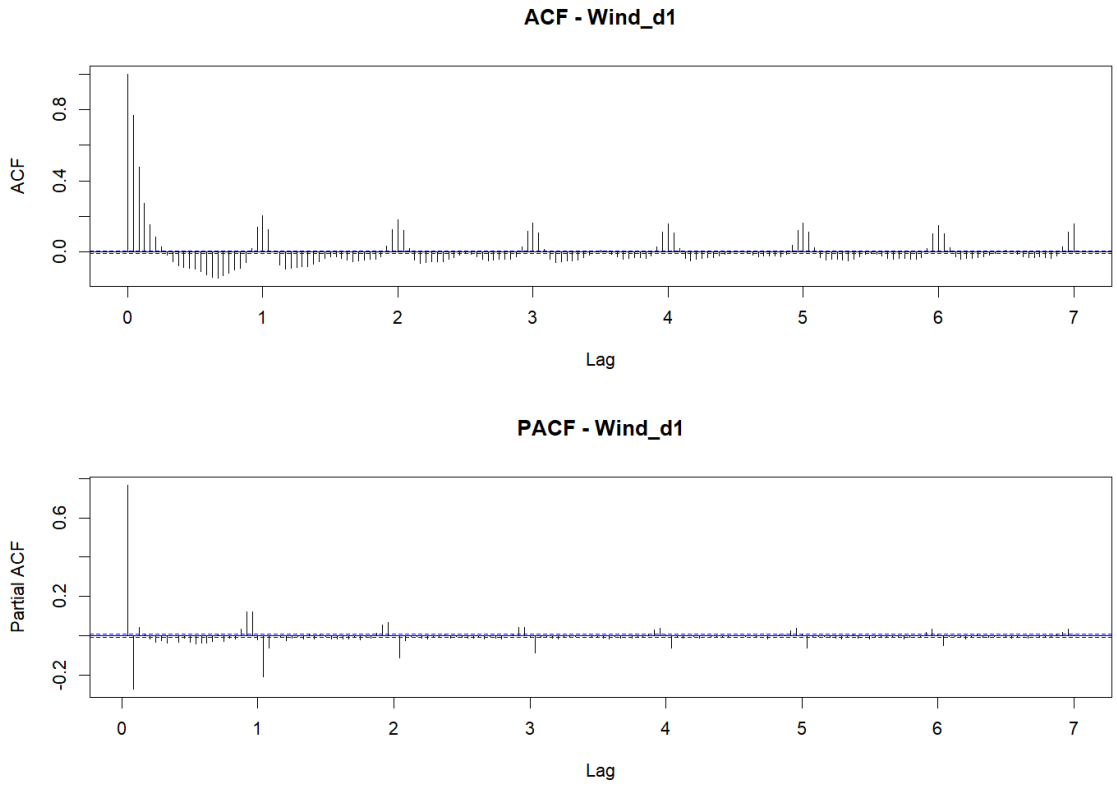


FIGURE 19 – ACF/PACF de `Wind` différenciée ($d1$, R).

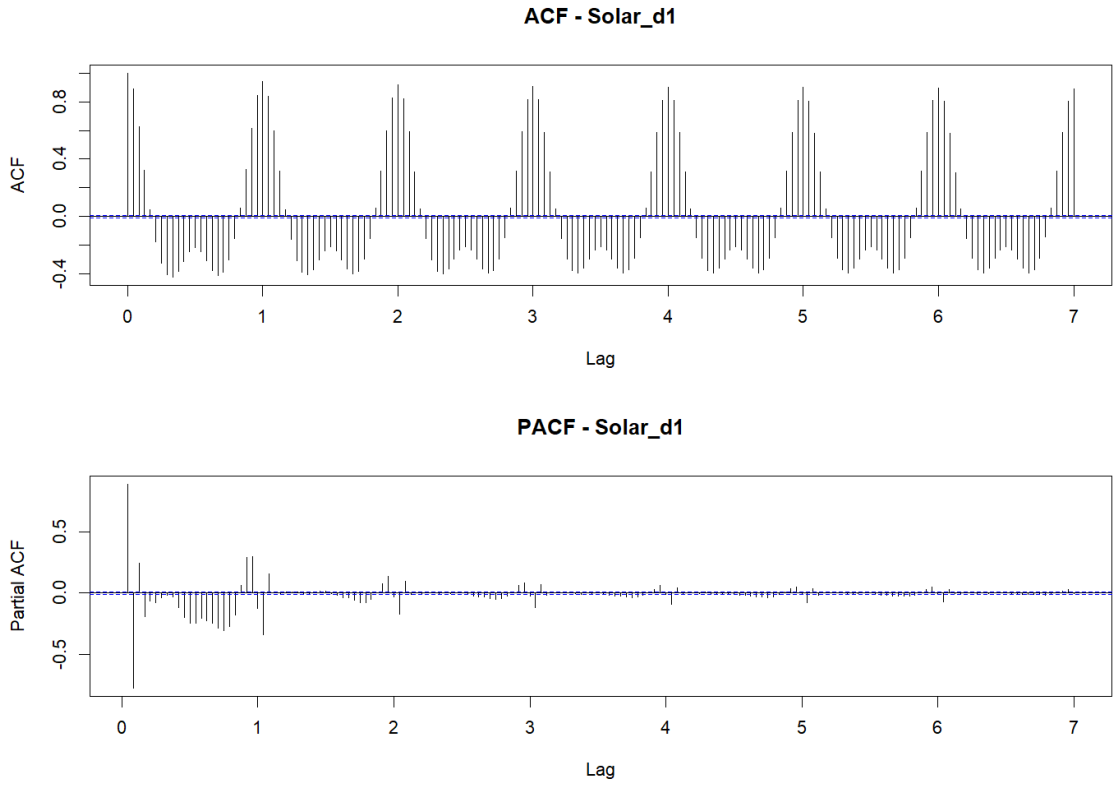


FIGURE 20 – ACF/PACF de `Solar` différenciée ($d1$, R).

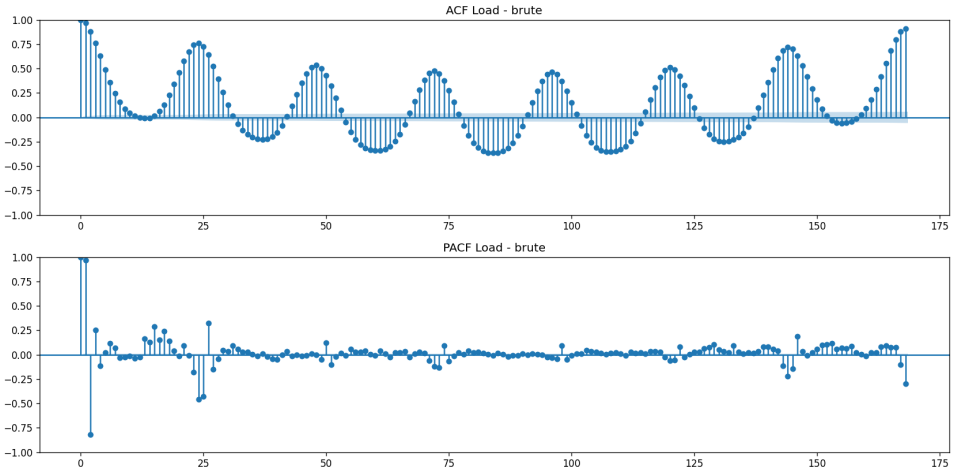


FIGURE 21 – ACF/PACF de `Load` brute (Python). À comparer avec la figure 15.

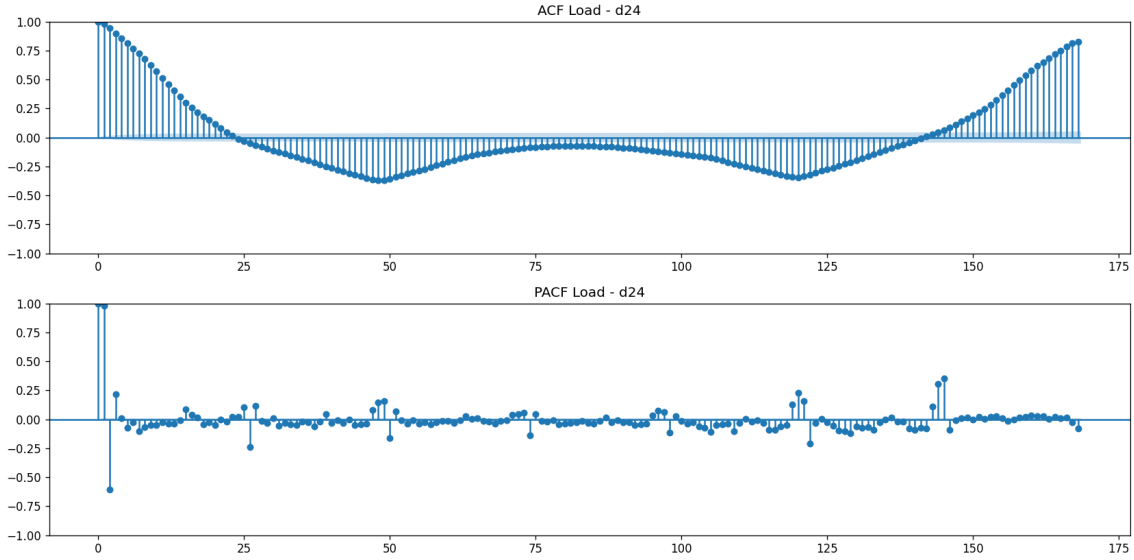


FIGURE 22 – ACF/PACF de `Load` en différence saisonnière ($d24$, Python).

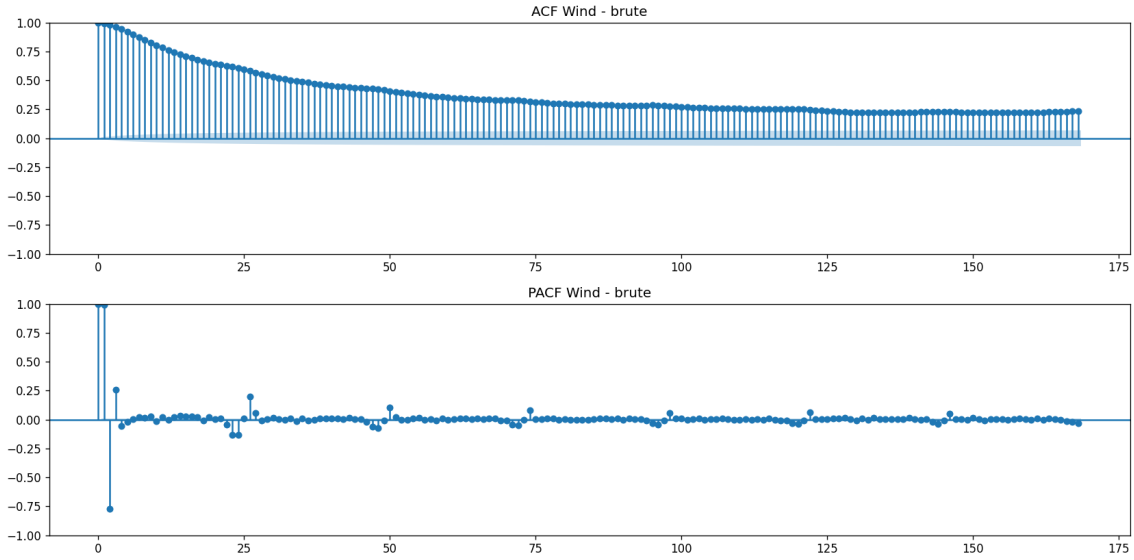


FIGURE 23 – ACF/PACF de `Wind` brute (Python).

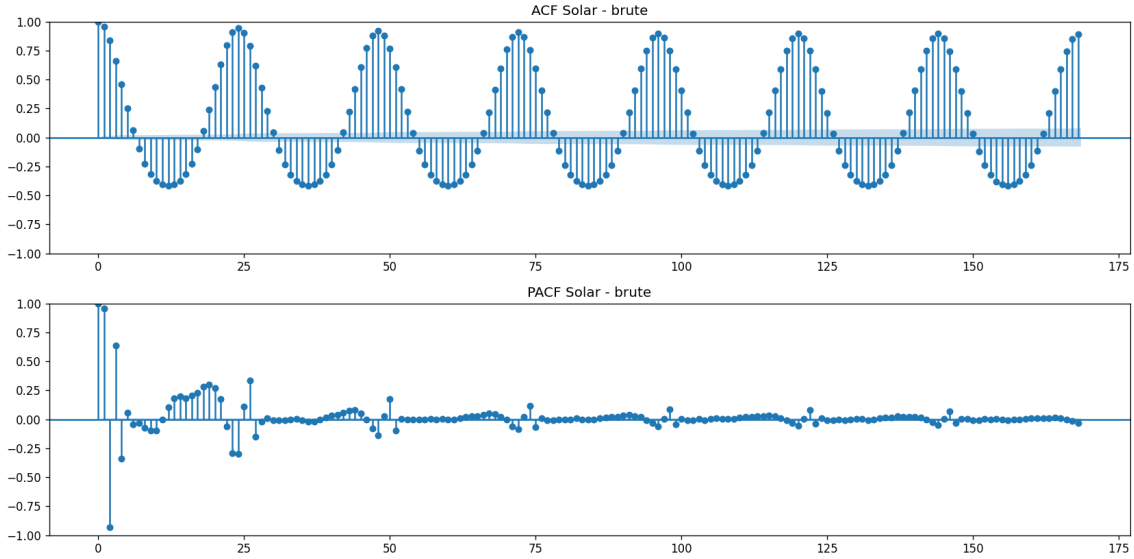


FIGURE 24 – ACF/PACF de `Solar` brute (Python).

3.2 Socle univarié : ARIMA / SARIMA

3.2.1 Sélection des modèles

Le tableau 5 (R) et le tableau 6 (Python) comparent les trois candidats par AIC/AICc/BIC. Les deux implémentations retiennent des ordres **identiques** :

— `Load` : `SARIMA_manuel` ARIMA$(1,1,1)(1,1,1)_{24}$ (AICc minimal) ;
— `Wind` : `SARIMA_manuel` également retenu ;
— `Solar` : `SARIMA_auto` ARIMA$(2,1,2)(0,1,1)_{24}$ au plus faible AICc.

Le modèle non saisonnier `ARIMA_auto` présente systématiquement un AICc nettement supérieur, confirmant la nécessité de la composante saisonnière $m = 24$.

TABLE 5 – Comparaison des modèles ARIMA/SARIMA (R). AICc minimal en gras. Source : `R_arima_model_comparison.csv`.

Variable	Modèle	AIC	AICc	BIC	Spécification
Load	SARIMA_manuel	740 406	**740 406,22**	740 450	ARIMA(1,1,1)(1,1,1)[24]
Load	ARIMA_auto	786 041	786 041,00	786 102	ARIMA(5,1,1)
Load	SARIMA_auto	752 342	752 341,81	752 394	ARIMA(2,1,2)(1,1,0)[24]
Wind	SARIMA_manuel	694 884	**694 884,46**	694 928	ARIMA(1,1,1)(1,1,1)[24]
Wind	ARIMA_auto	701 054	701 054,37	701 115	ARIMA(2,1,3)
Wind	SARIMA_auto	698 594	698 594,09	698 638	ARIMA(1,1,2)(1,0,0)[24]
Solar	SARIMA_manuel	656 144	656 143,85	656 187	ARIMA(1,1,1)(1,1,1)[24]
Solar	ARIMA_auto	700 943	700 943,17	700 987	ARIMA(2,1,2)
Solar	SARIMA_auto	650 435	**650 434,88**	650 487	ARIMA(2,1,2)(0,1,1)[24]

TABLE 6 – Comparaison des modèles ARIMA/SARIMA (Python) — confirme les ordres retenus en R. Source : `py_arima_model_comparison.csv`.

Variable	Modèle	AIC	AICc	BIC	Spécification
Load	SARIMA_manuel	739 990	739 990	740 033	ARIMA(1,1,1)(1,1,1)[24]
Load	ARIMA_auto	786 510	786 510	786 571	ARIMA(5,1,1)
Load	SARIMA_auto	752 042	752 042	752 095	ARIMA(2,1,2)(1,1,0)[24]
Wind	ARIMA_auto	701 099	701 099	701 152	ARIMA(2,1,3)
Wind	SARIMA_auto	698 280	698 280	698 324	ARIMA(1,1,2)(1,0,0)[24]
Solar	SARIMA_manuel	655 665	655 665	655 709	ARIMA(1,1,1)(1,1,1)[24]
Solar	ARIMA_auto	701 059	701 059	701 103	ARIMA(2,1,2)
Solar	SARIMA_auto	649 997	649 997	650 049	ARIMA(2,1,2)(0,1,1)[24]

3.2.2 Diagnostics des résidus

Le tableau 7 présente les diagnostics du meilleur modèle par série. Quelle que soit l'implémentation, les trois tests rejettent leurs hypothèses nulles : autocorrélation résiduelle partielle (Ljung–Box), non-normalité (Jarque–Bera) et surtout **effet ARCH persistant** (ARCH–LM), ce dernier point justifiant directement le volet GARCH (section 3.4).

TABLE 7 – Diagnostics des résidus du meilleur modèle ARIMA/SARIMA. Sources : `R_arima_diagnostics.csv` et `py_arima_diagnostics.csv`.

Impl.	Variable	Ljung–Box(24) p	Jarque–Bera p	ARCH–LM(12) p	Verdict
R	Load	< 0,001	< 0,001	< 0,001	Rejets
R	Wind	< 0,001	< 0,001	< 0,001	Rejets
R	Solar	< 0,001	< 0,001	< 0,001	Rejets
py	Load	0,000	0,000	7,2e-240	Rejets
py	Wind	1,6e-65	0,000	0,000	Rejets
py	Solar	6,2e-262	0,000	0,000	Rejets

3.2.3 Prévisions et métriques

Le tableau 8 donne l'intégralité des métriques R. Plusieurs enseignements se dégagent :

— À $h = 10$ et $h = 24$, les RMSE sont faibles pour `Load` (SARIMA_manuel : $\approx$ 899 puis 1 069 MW, soit MAPE $\approx 1{,}4\,\%$) et pour `Solar` (`SARIMA_auto` : RMSE ≈ 553 MW à $h = 10$) ;
— À $h = 5\,040$, en revanche, les erreurs explosent (RMSE de 65 847 MW pour `Load` SARIMA_manuel) : la prévision récursive sur 7 mois n'a plus de sens statistique, résultat documenté honnêtement ;
— le MAPE de `Solar` devient extrêmement élevé au voisinage des zéros (23 953 % à $h = 5\,040$), artefact bien connu de cette métrique lorsque le dénominateur s'annule.

Les prévisions (figures 25–27 et Python 28–30) et les graphiques de diagnostic des résidus (figures 31–33 et 34–36) confirment ces constats.

TABLE 8 – Métriques complètes ARIMA/SARIMA (R) aux horizons 10, 24 et 5 040. Source : `R_arima_metrics.csv`.

Variable	Modèle	h	MSE	RMSE	MAE	MAPE (%)
`Load`	SARIMA_manuel	10	806 545	898,1	745,6	1,39
`Load`	SARIMA_manuel	24	1 142 530	1 068,9	874,1	1,48
`Load`	SARIMA_manuel	5040	4,34e9	65 847	59 491	121,81
`Load`	ARIMA_auto	10	14 879 311	3 857,4	3 562,9	5,90
`Load`	ARIMA_auto	24	26 420 661	5 140,1	4 591,6	7,22
`Load`	ARIMA_auto	5040	1,77e8	13 290	10 813	24,60
`Load`	SARIMA_auto	10	3 569 054	1 889,2	1 874,9	3,22
`Load`	SARIMA_auto	24	2 815 028	1 677,8	1 462,1	2,41
`Load`	SARIMA_auto	5040	4,17e10	204 258	179 642	365,02
`Wind`	SARIMA_manuel	10	1 081 180	1 039,8	947,2	15,05
`Wind`	SARIMA_manuel	24	1,60e8	12 662	9 065	46,35
`Wind`	SARIMA_manuel	5040	3,48e10	186 572	163 714	3 574,82
`Wind`	ARIMA_auto	10	262 548	512,4	456,1	7,37
`Wind`	ARIMA_auto	24	1,40e8	11 835	8 049	37,55
`Wind`	ARIMA_auto	5040	9,25e7	9 620	6 795	90,02
`Wind`	SARIMA_auto	10	529 261	727,5	571,1	8,83
`Wind`	SARIMA_auto	24	1,70e8	13 022	9 029	43,45
`Wind`	SARIMA_auto	5040	1,20e8	10 964	7 703	71,79
`Solar`	SARIMA_manuel	10	603 717	777,0	447,7	39,13
`Solar`	SARIMA_manuel	24	597 424	772,9	472,9	40,00
`Solar`	SARIMA_manuel	5040	5,37e7	7 330	4 657	378,19
`Solar`	ARIMA_auto	10	23 253 107	4 822,1	2 570,5	89,71
`Solar`	ARIMA_auto	24	31 935 427	5 651,1	3 221,8	97,11
`Solar`	ARIMA_auto	5040	1,44e8	12 020	7 605	101,74
`Solar`	SARIMA_auto	10	307 488	554,5	382,2	558,38
`Solar`	SARIMA_auto	24	699 481	836,3	585,1	1 424,44
`Solar`	SARIMA_auto	5040	5,93e7	7 700	6 350	23 953,09

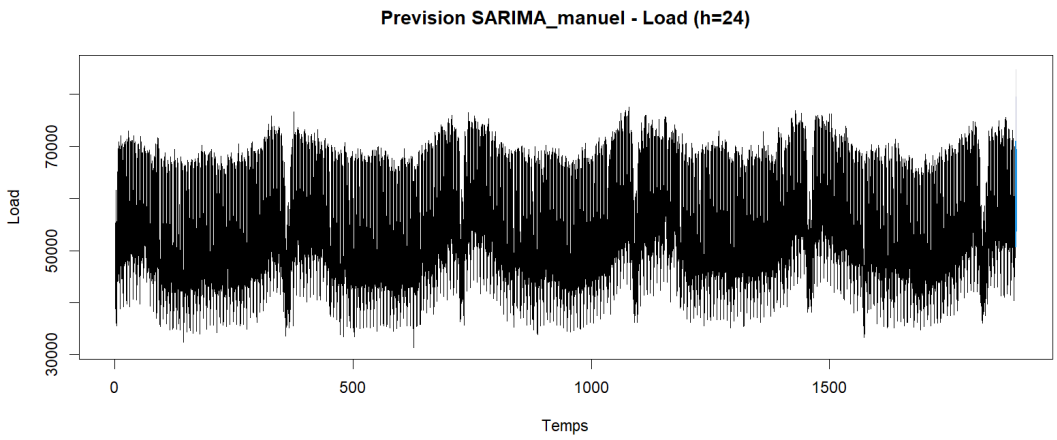


FIGURE 25 – Prévision `Load` à $h = 24$ (modèle retenu, R).

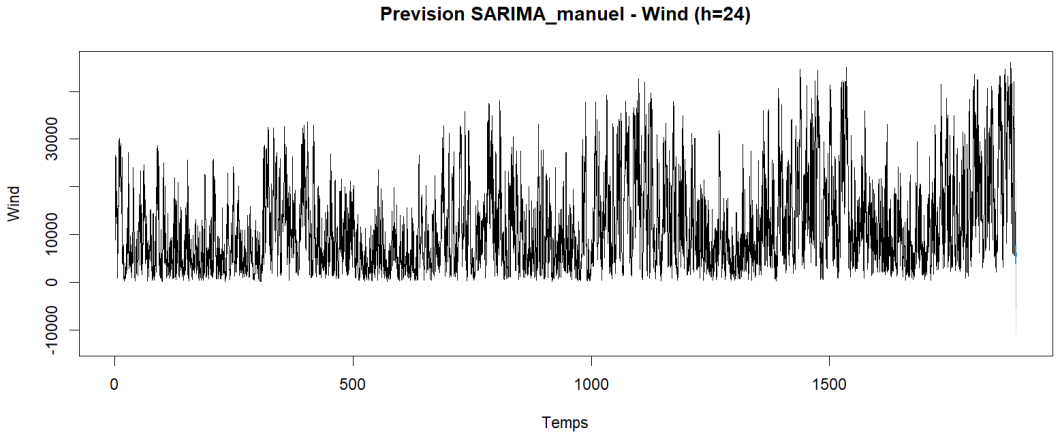


FIGURE 26 – Prévision `Wind` à $h = 24$ (R).

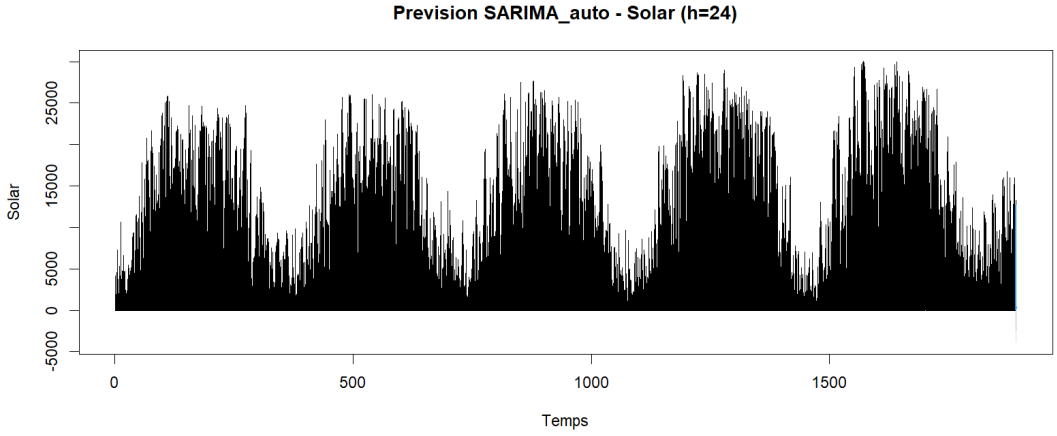


FIGURE 27 – Prévision `Solar` à $h = 24$ (R).

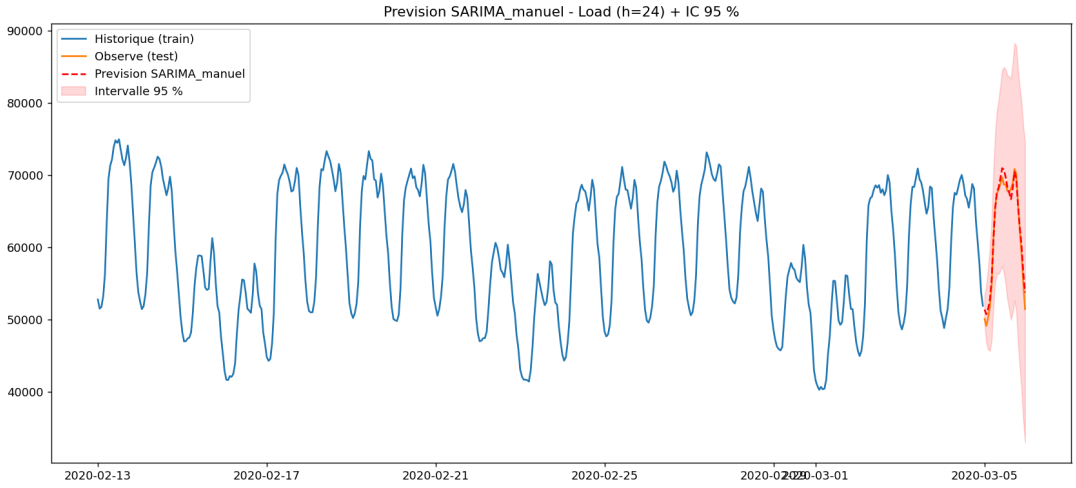


FIGURE 28 – Prévision `Load` (Python) — cohérente avec R.

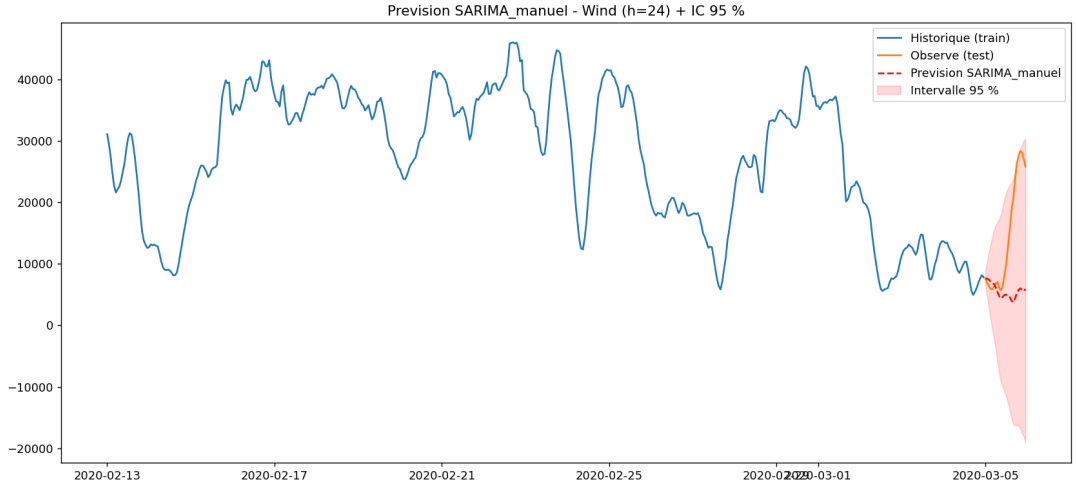


FIGURE 29 – Prévision `Wind` (Python).

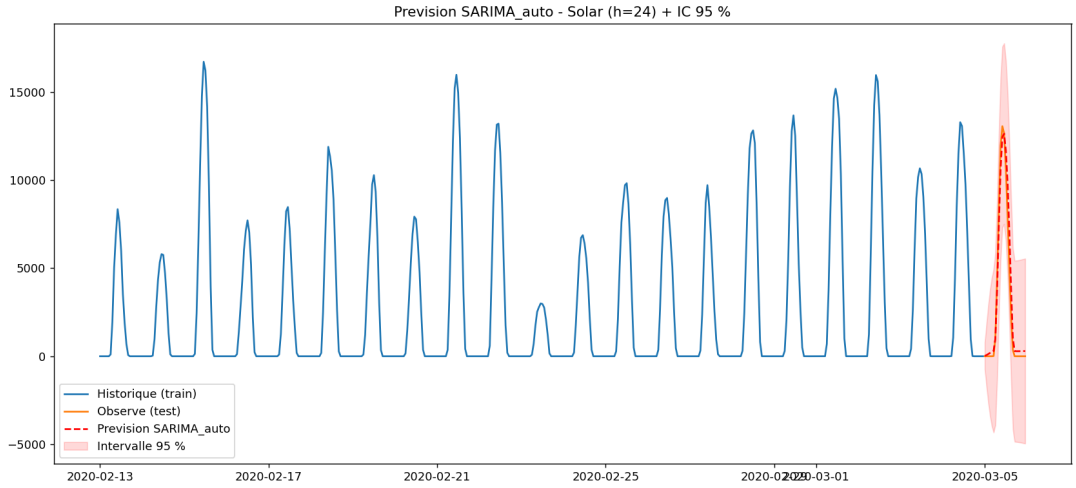


FIGURE 30 – Prévision `Solar` (Python).

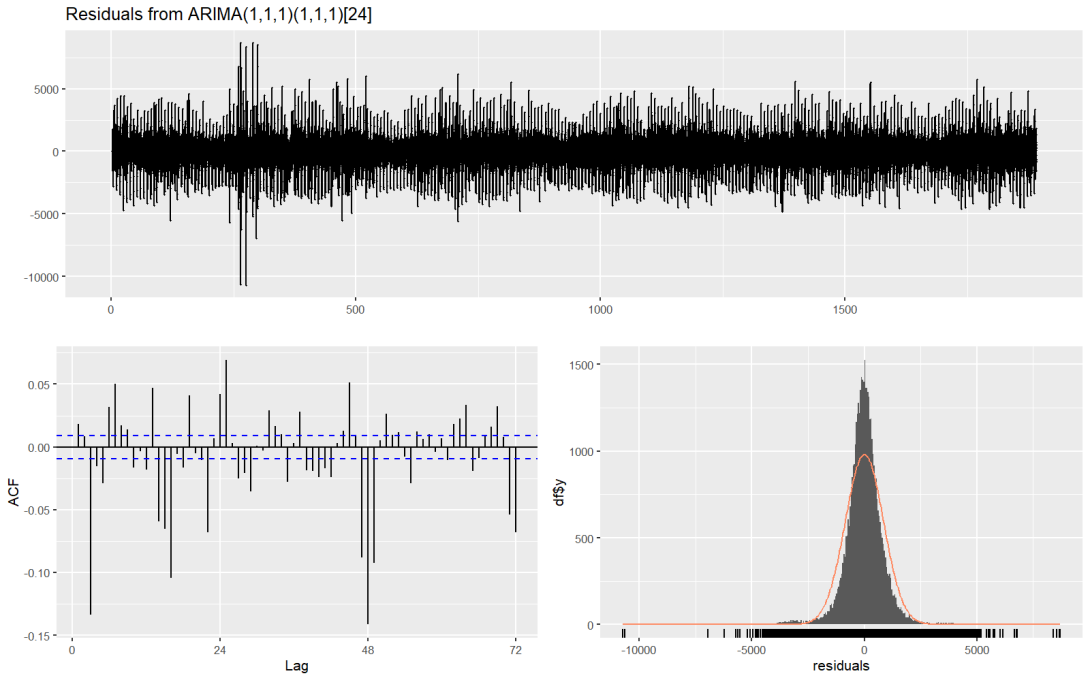


FIGURE 31 – Diagnostic des résidus `Load` (R).

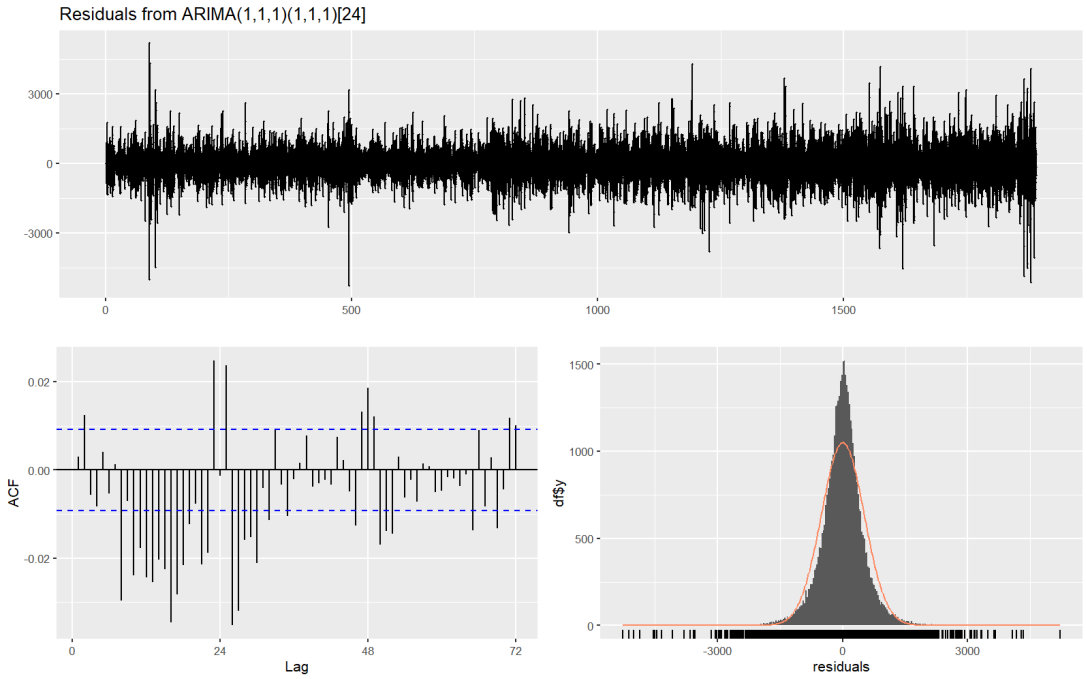


FIGURE 32 – Diagnostic des résidus `Wind` (R).

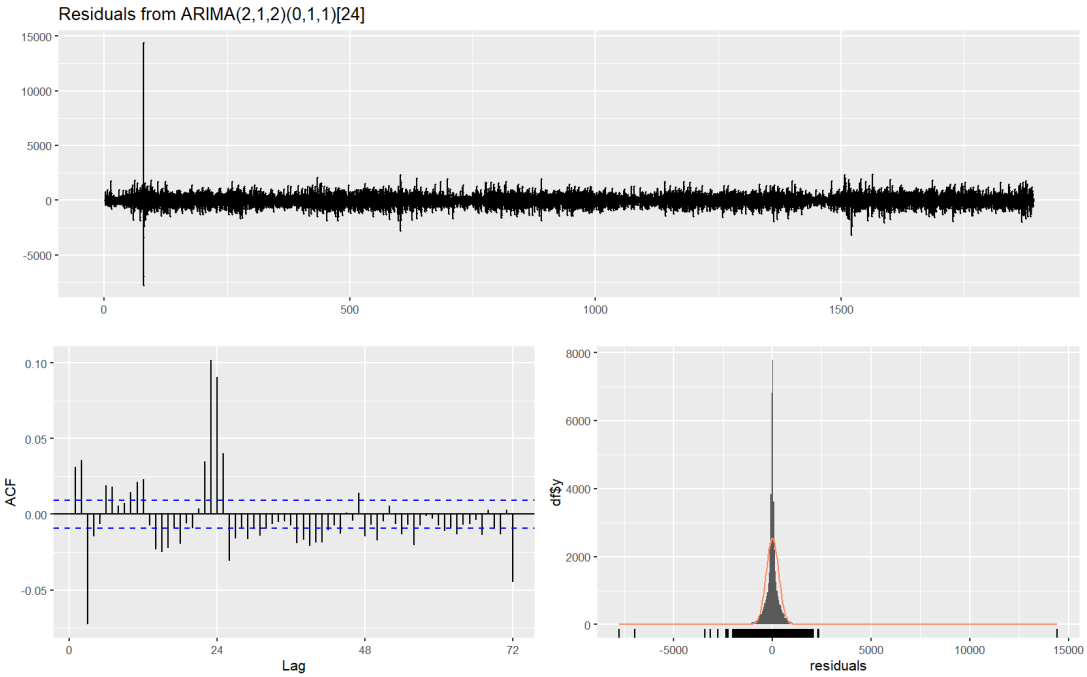


FIGURE 33 – Diagnostic des résidus `Solar` (R).

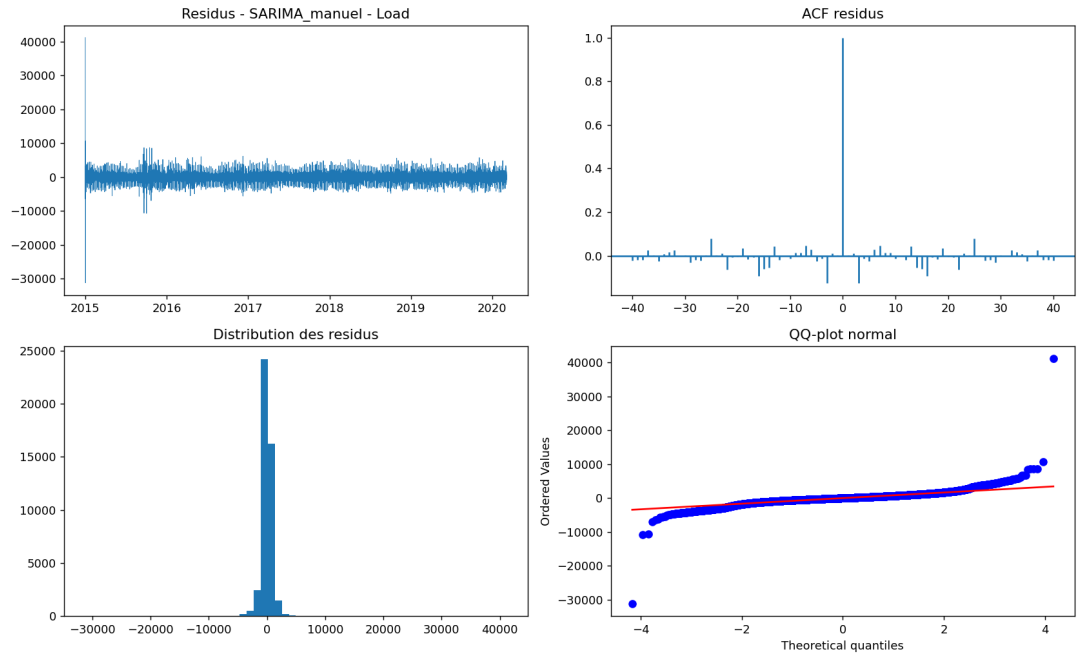


FIGURE 34 – Diagnostic des résidus `Load` (Python).

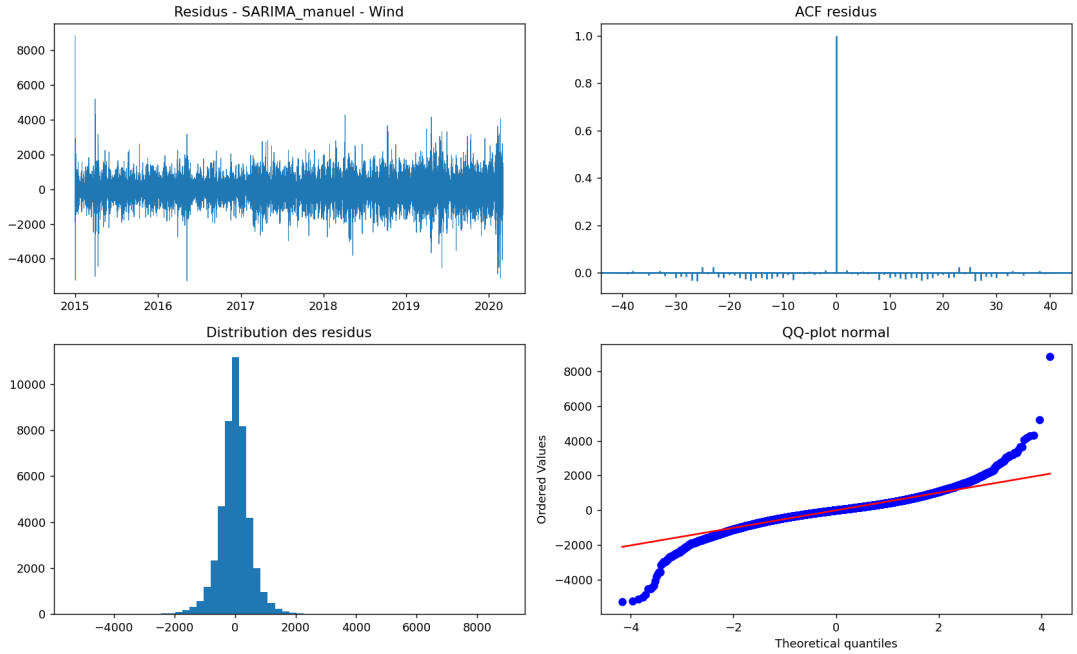


FIGURE 35 – Diagnostic des résidus `Wind` (Python).

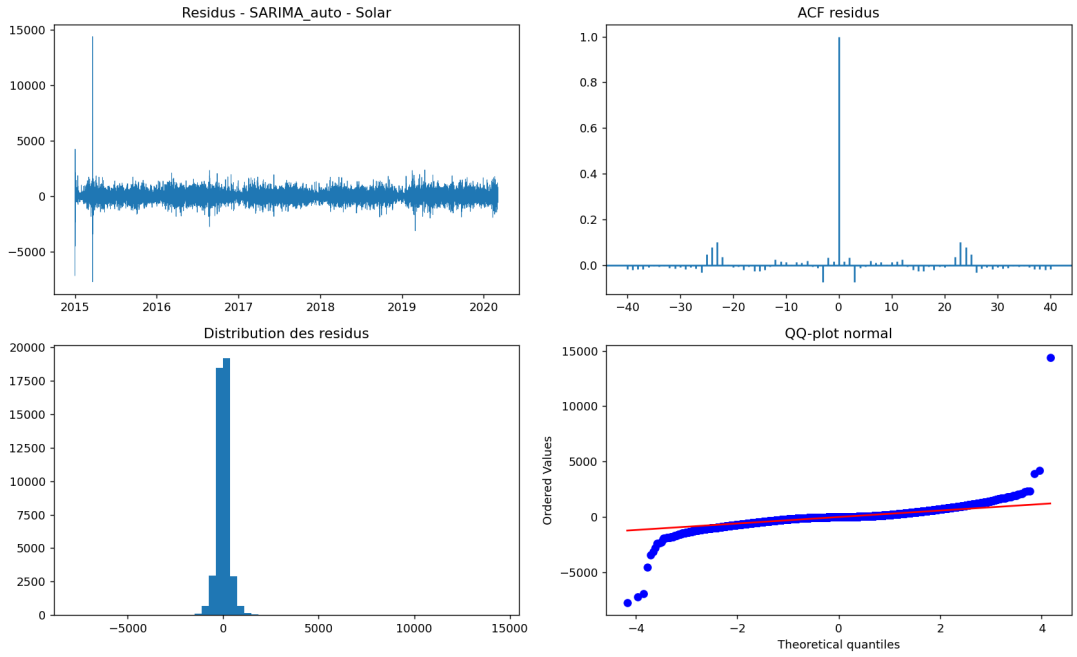


FIGURE 36 – Diagnostic des résidus `Solar` (Python).

3.3 Liaisons dynamiques : VAR, Granger, Johansen, VECM

3.3.1 Sélection de l'ordre du VAR

Le tableau 9 (extrait de `R_var_order.csv`) montre que le critère AIC atteint son minimum à $p = 14$ (sur les moyennes journalières différenciées), retenu pour la suite. Les critères HQ/SC suggèrent un ordre plus faible, mais l'AIC est privilégié pour ne pas sous-paramétrer la dynamique. Python aboutit au même ordre (`py_var_order.csv`).

TABLE 9 – Critères d'information pour la sélection de l'ordre du VAR (R). Source : `R_var_order.csv`.

Critère	10	11	12	13	**14**	15
AIC	47,540	47,534	47,510	47,432	**47,375**	47,378
HQ	47,641	47,645	47,631	47,563	**47,516**	47,528
SC	47,815	47,835	47,838	47,787	**47,757**	47,786
FPE	4,43e20	4,40e20	4,30e20	3,98e20	**3,76e20**	3,77e20

3.3.2 Causalité de Granger

Le tableau 10 teste les six relations ordonnées. Seule l'hypothèse `Wind` → `Load` est rejetée (R : $p = 0{,}013$; Python : $p = 0{,}002$), c'est-à-dire que la production éolienne **cause** la consommation au sens de Granger. Aucune des autres directions n'est significative.

TABLE 10 – Test de causalité de Granger (R et Python). Sources : `R_granger.csv`, `py_granger.csv`.

Hypothèse	p (R)	p (py)	Conclusion
`Wind` → `Load`	**0,0126**	**0,0022**	Oui (rejet H0)
`Solar` → `Load`	0,767	0,256	Non
`Load` → `Wind`	0,244	0,157	Non
`Solar` → `Wind`	0,371	0,339	Non
`Load` → `Solar`	0,738	0,752	Non
`Wind` → `Solar`	0,099	0,058	Non

3.3.3 Cointégration de Johansen et VECM

Le test de trace de Johansen (tableau 11) conduit à $r = 2$ relations de cointégration : au premier rang, la statistique (155,32) dépasse largement la valeur critique (34,91) ; au second rang (58,54) elle dépasse encore 19,96 ; au troisième rang (8,67) elle passe sous 9,24. Ce résultat est **identique** en R et en Python.

TABLE 11 – Test de trace de Johansen (valeurs critiques à 95 %). Sources : `R_johansen.csv`, `py_johansen.csv`.

Rang testé	Stat. (R)	Stat. (py)	CV 95 %	Conclusion
$r = 0$	152,97	155,32	34,91	Rejet $r = 0$
$r \leq 1$	57,83	58,54	19,96	Rejet $r \leq 1$
$r \leq 2$	8,66	8,67	9,24	Non rejeté

Le VECM estimé (tableaux 12 et 13) fournit des vecteurs de cointégration β normalisés très proches en R et Python (`Solar` : $\approx 0{,}91$ et $\approx 1{,}22$ sur les deux relations) et des vitesses d'ajustement α cohérentes : la charge et l'éolien présentent une force de rappel significative ($\alpha \approx -0{,}24$ pour `Load` dans l'équation 1 et `Wind` dans l'équation 2), tandis que le solaire s'ajuste très peu.

TABLE 12 – Vecteurs de cointégration normalisés β du VECM ($r = 2$). Sources : `R_vecm.csv`, `py_vecm.csv`.

Variable (lag 1)	ECT_1	ECT_2
`Load`	1,0000	0,0000
`Wind`	0,0000	1,0000
`Solar`	0,9084 (py 0,9148)	1,2126 (py 1,2222)
Constante	−59 819 (py −59 848)	−16 705 (py −16 780)

TABLE 13 – Vitesses d'ajustement α du VECM. Sources : `R_vecm_alpha.csv`, `py_vecm_alpha.csv`.

Équation	ΔLoad	ΔWind	ΔSolar
ECT_1	−0,2379	0,1196	0,0030
ECT_2	0,0161	−0,2396	0,0063

3.3.4 Diagnostics du VAR

Le tableau 14 indique le rejet des trois tests : le VAR journalier laisse une autocorrélation, une non-normalité et surtout un effet **ARCH multivarié**, ce qui confirme une nouvelle fois le besoin d'une modélisation explicite de la volatilité.

TABLE 14 – Diagnostics multivariés du VAR. Sources : `R_var_diagnostics.csv`, `py_var_diagnostics.csv`.

Test	p (R)	p (py)
Portmanteau (autocorrélation)	$< 0{,}001$	5,0e-40
Normalité multivariée (JB)	$< 0{,}001$	$< 0{,}001$
ARCH multivarié (Load)	$< 0{,}001$	1,1e-24
ARCH multivarié (Wind)	—	2,6e-16
ARCH multivarié (Solar)	—	4,6e-15

3.3.5 Réponse impulsionnelle et décomposition de la variance

Les figures 37 et 38 (et leurs homologues Python 39 et 40) synthétisent les dynamiques. La décomposition de variance à 28 jours (tableau 15) montre que chaque série est essentiellement expliquée par elle-même (92 à 97 %), avec une contribution de `Wind` à `Load` d'environ 2,2 % et de `Solar` à `Load` d'environ 4,1 % — cohérent avec la causalité de Granger détectée.

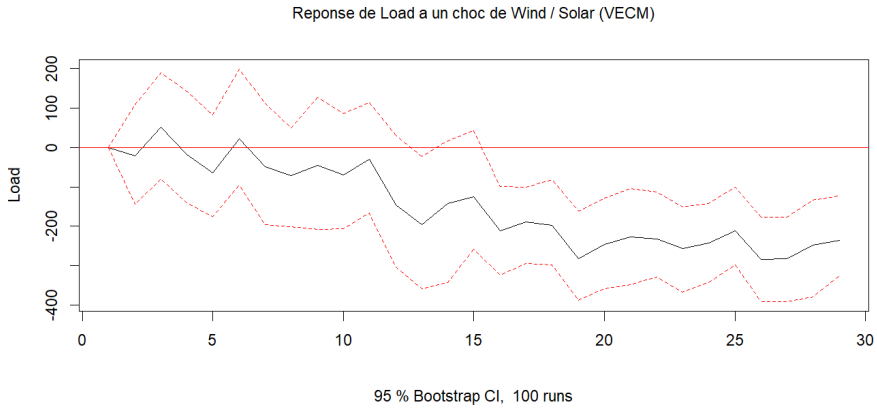


FIGURE 37 – Réponse de `Load` à un choc de `Wind`/`Solar` (R, 28 jours).

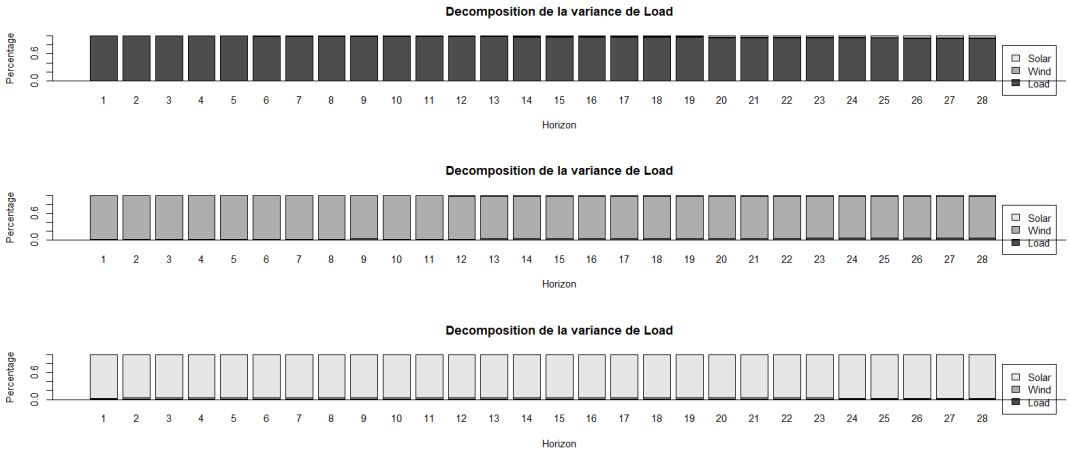


FIGURE 38 – Décomposition de la variance de `Load` (R).

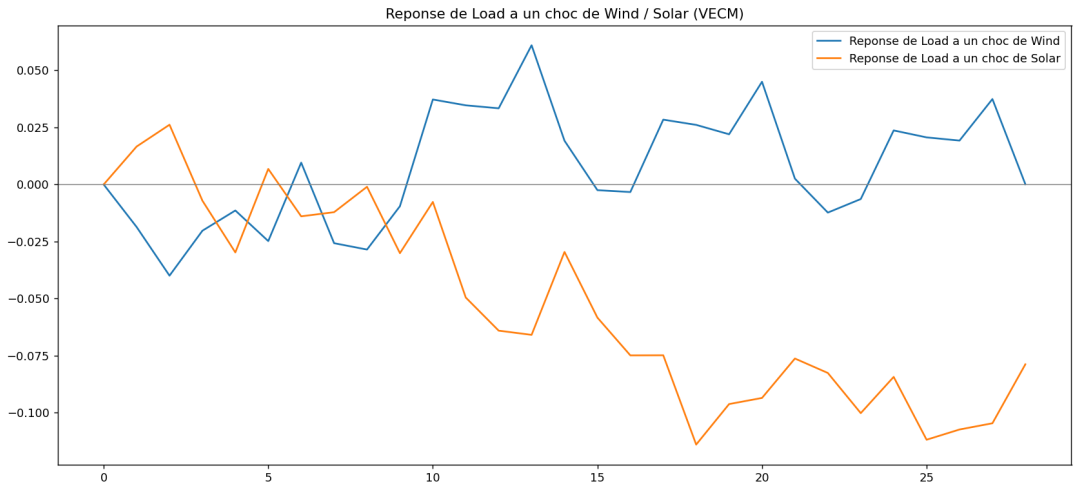


FIGURE 39 – Réponse de `Load` à un choc (Python).

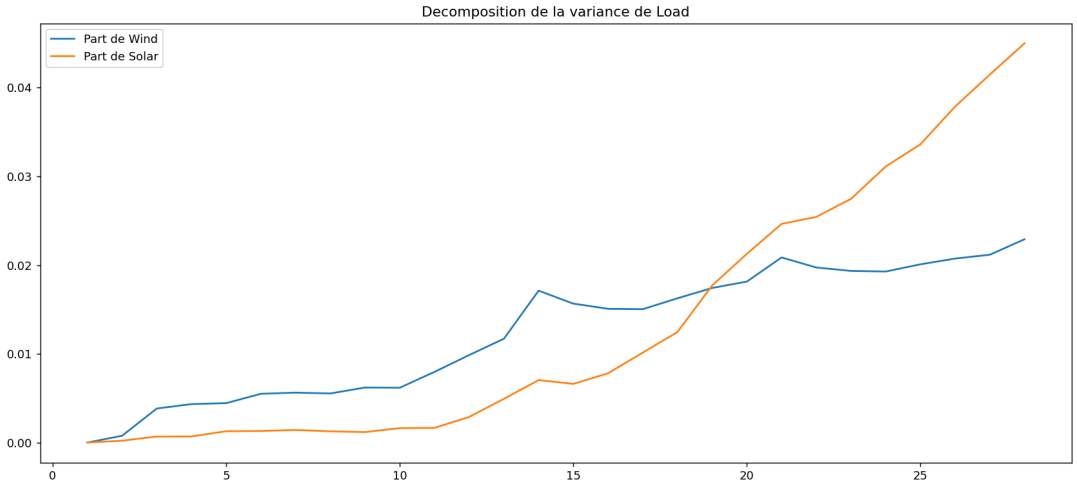


FIGURE 40 – Décomposition de la variance de `Load` (Python).

TABLE 15 – Décomposition de la variance au jour 28 (R). Source : `R_var_fevd.csv`.

Variable expliquée	Part `Load`	Part `Wind`	Part `Solar`
`Load`	0,9368	0,0219	0,0413
`Wind`	0,0459	0,9243	0,0298
`Solar`	0,0080	0,0213	0,9708

3.4 Modélisation de la volatilité : ARCH / GARCH

3.4.1 Persistance de la volatilité

Le tableau 16 (R) et le tableau 17 (Python) résument la persistance. Pour `Wind`, les trois spécifications sont covariation-stationnaires avec une persistance très élevée ($\approx 0{,}99$), soit une demi-vie de 68 (GARCH(1,1)) à 675 (EGARCH) jours. Pour `Load`, GARCH(1,1) est proche de la frontière (persistance $\approx 0{,}998$ en R). Pour `Solar`, GARCH(1,1) et GARCH(2,1) sont non stationnaires (persistance ≥ 1), seul l'EGARCH(1,1) reste stable ($\approx 0{,}99$).

TABLE 16 – Persistance de la volatilité (R). Source : `R_garch_persistence.csv`.

Variable	Modèle	Persistance	Demi-vie (j)	Cov. stationnaire
`Load`	GARCH(1,1)	0,9981	366,8	Oui
`Load`	GARCH(2,1)	0,4540	0,9	Oui
`Load`	EGARCH(1,1)	0,6312	1,5	Oui
`Wind`	GARCH(1,1)	0,9899	68,5	Oui
`Wind`	GARCH(2,1)	0,9875	55,3	Oui
`Wind`	EGARCH(1,1)	0,9990	675,2	Oui
`Solar`	GARCH(1,1)	1,0050	NA	Non
`Solar`	GARCH(2,1)	1,0051	NA	Non
`Solar`	EGARCH(1,1)	0,9936	108,3	Oui

Table 17 – Persistance de la volatilité (Python). Source : `py_garch_persistence.csv`.

Variable	Modèle	Persistance	Demi-vie (j)	Convergence
`Load`	GARCH(1,1)	—	—	Non
`Load`	GARCH(2,1)	0,8222	3,5	Oui
`Load`	EGARCH(1,1)	—	—	Non
`Wind`	GARCH(1,1)	0,9905	72,7	Oui
`Wind`	GARCH(2,1)	0,9892	63,6	Oui
`Wind`	EGARCH(1,1)	0,9861	49,3	Oui
`Solar`	GARCH(1,1)	1,0000	—	Non
`Solar`	GARCH(2,1)	1,0000	—	Non
`Solar`	EGARCH(1,1)	0,9894	65,0	Oui

3.4.2 Coefficients estimés

Le tableau 18 détaille les coefficients estimés en Python (avec AIC/BIC et paramètre de queue lourde ν_t). On note pour `Wind` un $\beta_1 \approx 0{,}935$ (persistance de la volatilité) et pour `Solar` un $\nu_t \approx 8{,}7$, confirmant des queues plus épaisses que la normale.

Table 18 – Coefficients GARCH estimés (Python). Source : `py_garch_coefficients.csv`.

Variable	Modèle	μ	ω	α_1	β_1	Pers.	ν_t
`Load`	GARCH(2,1)	−0,186	1,296	0,0013	0,8209	0,822	2,05
`Wind`	GARCH(1,1)	−0,004	0,0113	0,0553	0,9352	0,991	7,35
`Wind`	EGARCH(1,1)	−0,005	0,0039	0,1205	0,9861	0,986	7,33
`Solar`	GARCH(1,1)	−0,001	0,0042	0,0890	0,9110	1,000	8,72
`Solar`	EGARCH(1,1)	0,000	0,0056	0,1942	0,9894	0,989	8,09

3.4.3 Diagnostics GARCH et volatilité conditionnelle

Le tableau 19 montre que les résidus standardisés du GARCH(1,1) ne sont plus autocorrélés (Ljung–Box des résidus) et que, pour `Solar`, les résidus au carré ne présentent plus d'effet ARCH (GARCH capture bien la volatilité), tandis que la non-normalité persiste (attendu avec une loi de Student).

Table 19 – Diagnostics du GARCH(1,1). Sources : `R_garch_diagnostics.csv`, `py_garch_diagnostics.csv`.

Impl.	Variable	LB résidus p	LB résidus^2 p	JB p
R	`Load`	0,000	0,000	0,000
R	`Wind`	0,000	0,010	0,000
R	`Solar`	0,000	0,780	3,9e-11
py	`Load`	0,000	0,000	1,2e-86
py	`Wind`	8,2e-25	0,015	3,7e-21
py	`Solar`	8,1e-26	0,850	3,7e-11

Les figures 41–43 (R) et 44–46 (Python) représentent la volatilité conditionnelle σ_t estimée et les épisodes de forte volatilité.

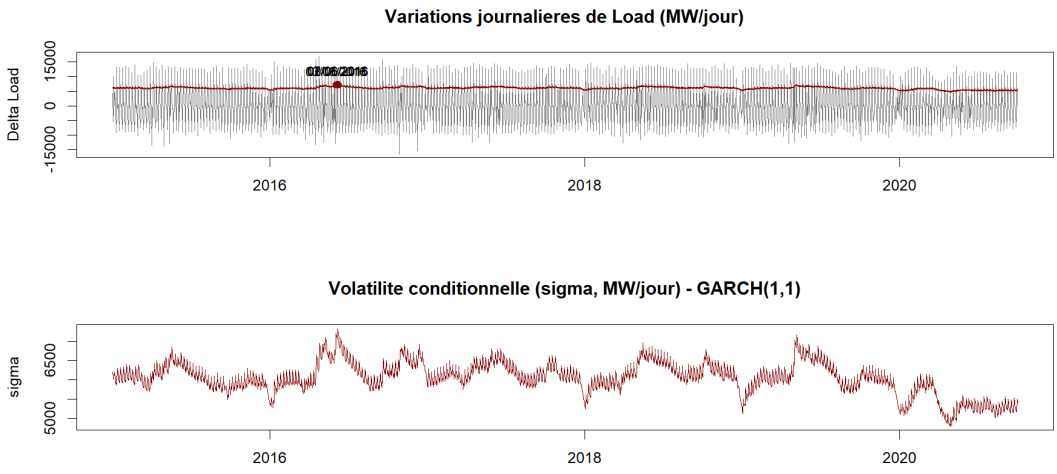


FIGURE 41 – Volatilité conditionnelle `Load` (GARCH(1,1), R).

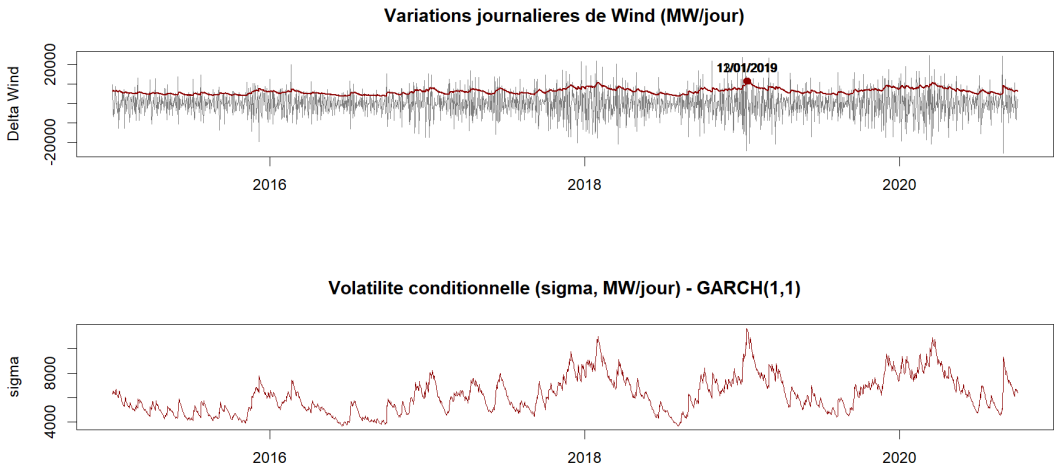


FIGURE 42 – Volatilité conditionnelle `Wind` (GARCH(1,1), R).

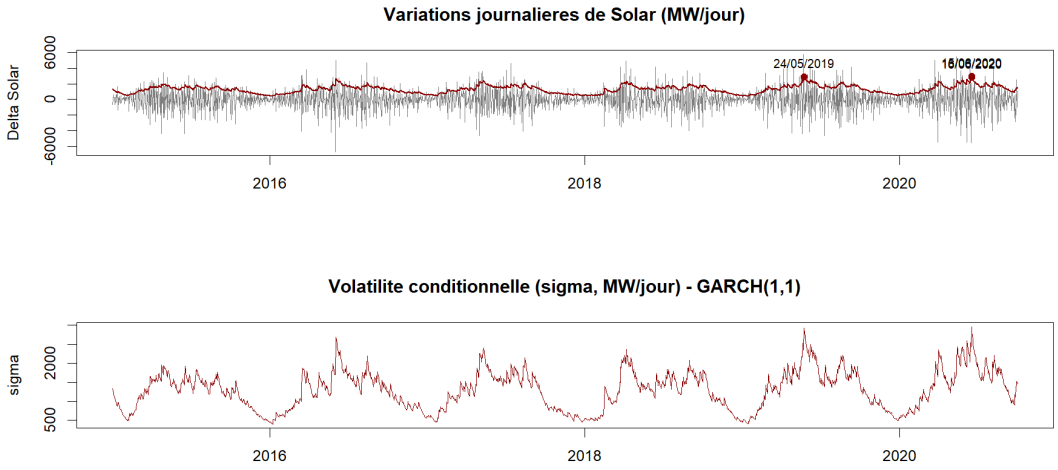


FIGURE 43 – Volatilité conditionnelle `Solar` (GARCH(1,1), R).

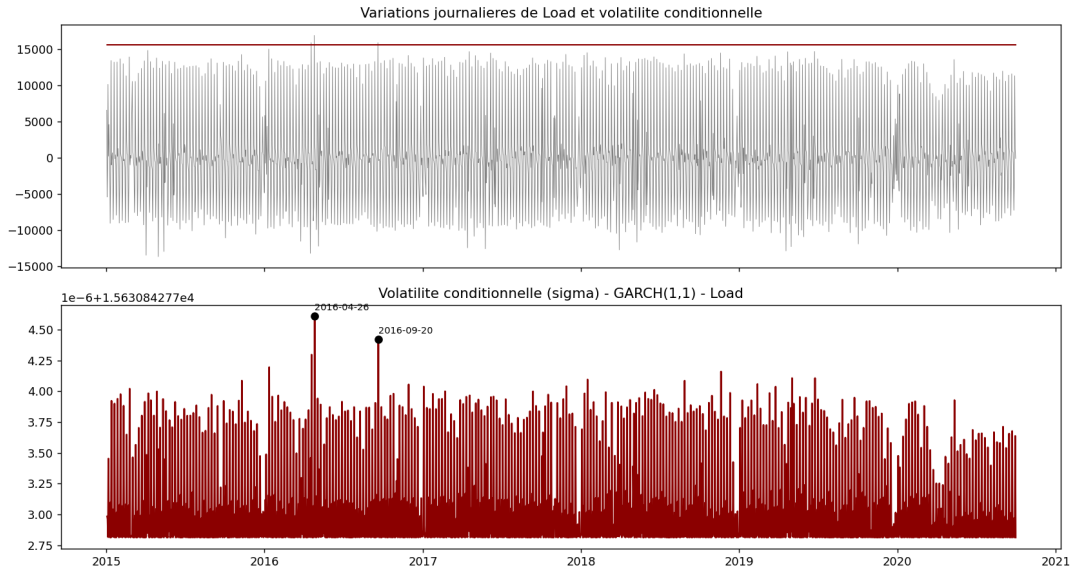


FIGURE 44 – Volatilité conditionnelle `Load` (Python).

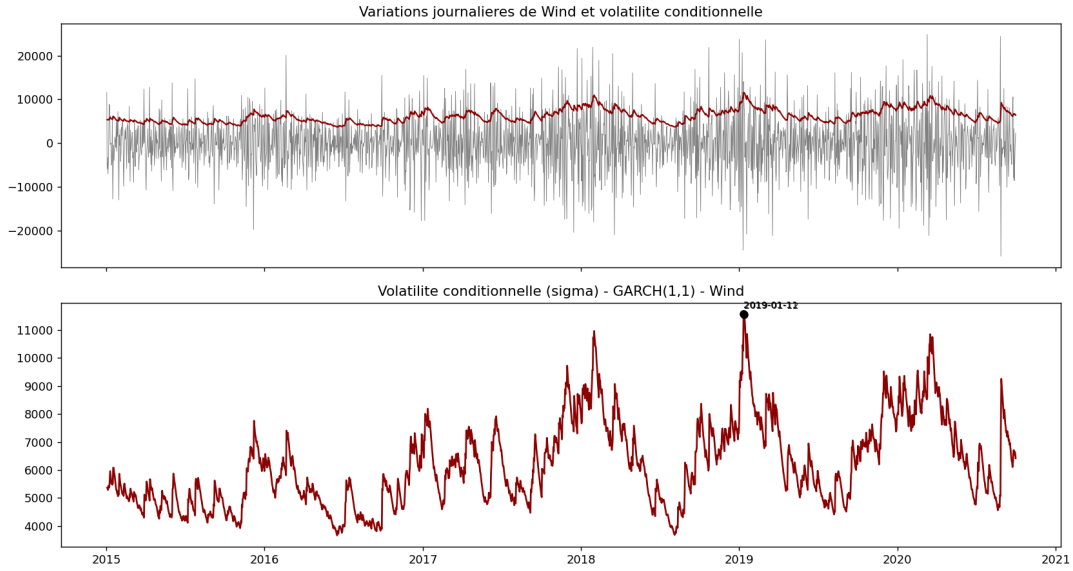


FIGURE 45 – Volatilité conditionnelle `Wind` (Python).

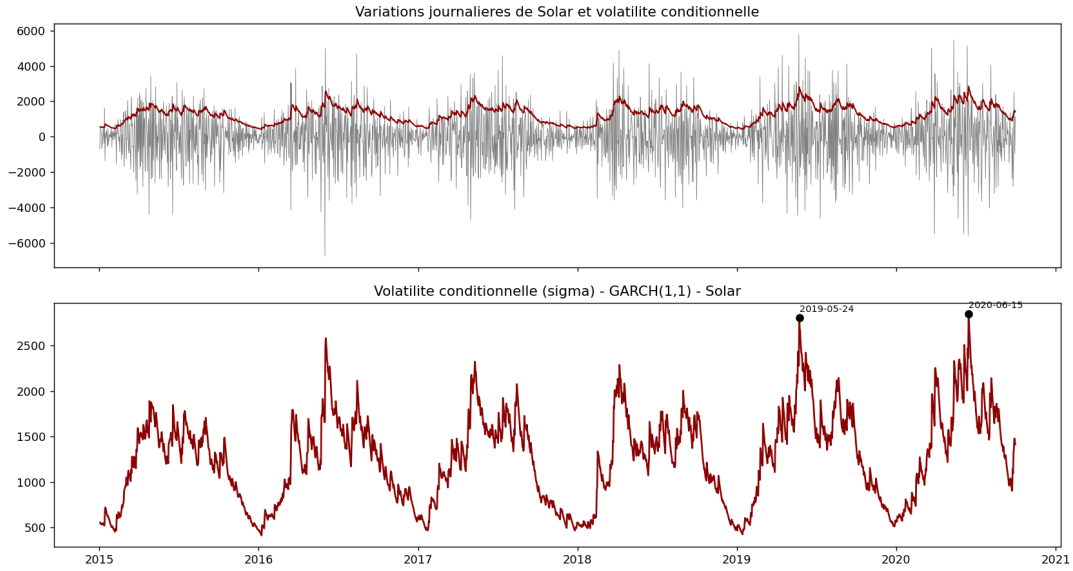


FIGURE 46 – Volatilité conditionnelle `Solar` (Python).

3.5 Modèles profonds : LSTM / GRU

Deux architectures récurrentes (LSTM et GRU), régularisées par une couche de **Dropout** ($p = 0{,}2$), sont entraînées par série avec une fenêtre glissante de 168 h et une prévision récursive ; la meilleure architecture (sur la `val_loss`) est conservée. Le tableau 20 présente les métriques des deux réseaux : la sélection retient le **LSTM** pour `Load` et `Solar`, le **GRU** pour `Wind`. À $h = 10$, le LSTM atteint une RMSE de 1 263,0 MW sur `Load` (MAPE = 1,57 %). À $h = 5\,040$, le LSTM reste le plus performant sur `Load` (7 592,7 MW, à comparer aux 65 847 MW de SARIMA_manuel), tandis que le GRU domine sur `Wind` (8 567,3 MW contre 11 858,4 pour le LSTM). Sur `Solar`, le MAPE devient astronomique ($\sim 1{,}7 \times 10^{14}$ %) : artefact documenté dû aux valeurs proches de zéro la nuit.

TABLE 20 – Métriques LSTM/GRU (Python). Source : `py_lstm_gru_metrics.csv`.

Variable	Modèle	h	RMSE	MAE	MAPE (%)
`Load`	LSTM	10	1 263,0	967,8	1,57
`Load`	LSTM	24	1 918,7	1 555,9	2,44
`Load`	LSTM	5040	7 592,7	6 137,2	13,00
`Load`	GRU	10	2 708,3	2 259,0	3,60
`Load`	GRU	24	8 406,2	6 593,0	9,95
`Load`	GRU	5040	9 033,5	7 809,0	15,83
`Wind`	LSTM	10	3 120,0	2 819,3	45,38
`Wind`	LSTM	24	7 870,1	6 203,7	42,78
`Wind`	LSTM	5040	11 858,4	10 584,9	296,93
`Wind`	GRU	10	2 060,4	1 847,2	29,89
`Wind`	GRU	24	9 277,6	6 759,1	38,99
`Wind`	GRU	5040	8 567,3	6 993,9	172,26
`Solar`	LSTM	10	573,8	420,1	5,9e12
`Solar`	LSTM	24	579,0	447,7	6,1e12
`Solar`	LSTM	5040	11 368,4	8 398,9	1,7e14
`Solar`	GRU	10	3 334,2	2 480,1	6,2e13
`Solar`	GRU	24	4 092,7	3 171,4	8,4e13
`Solar`	GRU	5040	10 534,3	7 430,5	8,8e13

Validation croisée temporelle (TSCV). Une validation croisée à fenêtre expansive ($k = 3$ plis) confirme la stabilité des réseaux : la RMSE de validation décroît puis se stabilise à mesure que le train s'allonge (`Load` : 2 178 → 1 907 MW pour le LSTM ; `Wind` : 957 → 876 MW pour le GRU ; `Solar` : 1 422 → 1 146 MW pour le LSTM). Source : `py_lstm_gru_cv.csv`.

Les figures 47–49 comparent prévisions et valeurs réelles, et les figures de *loss* (50–52) illustrent la convergence de l'apprentissage (train/validation).

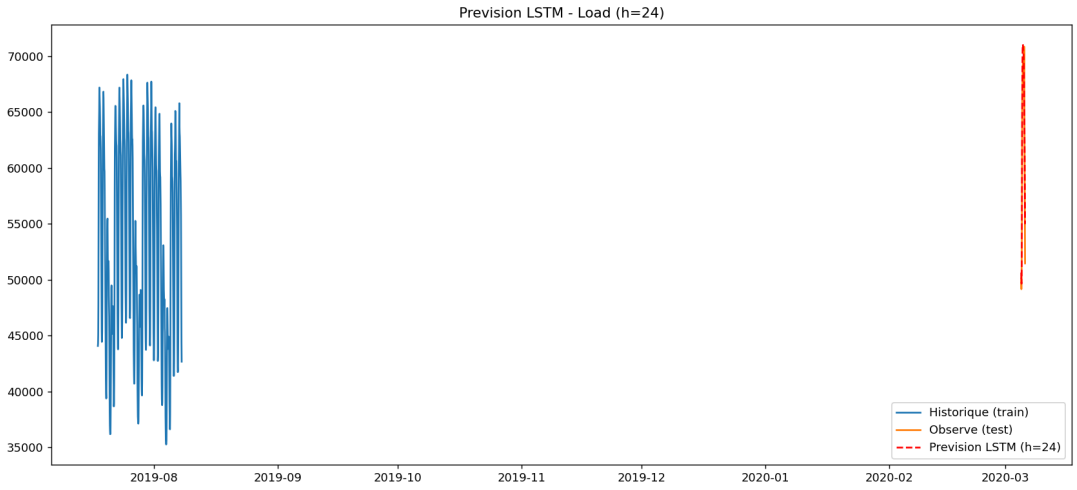


FIGURE 47 – Prévisions LSTM/GRU – `Load`.

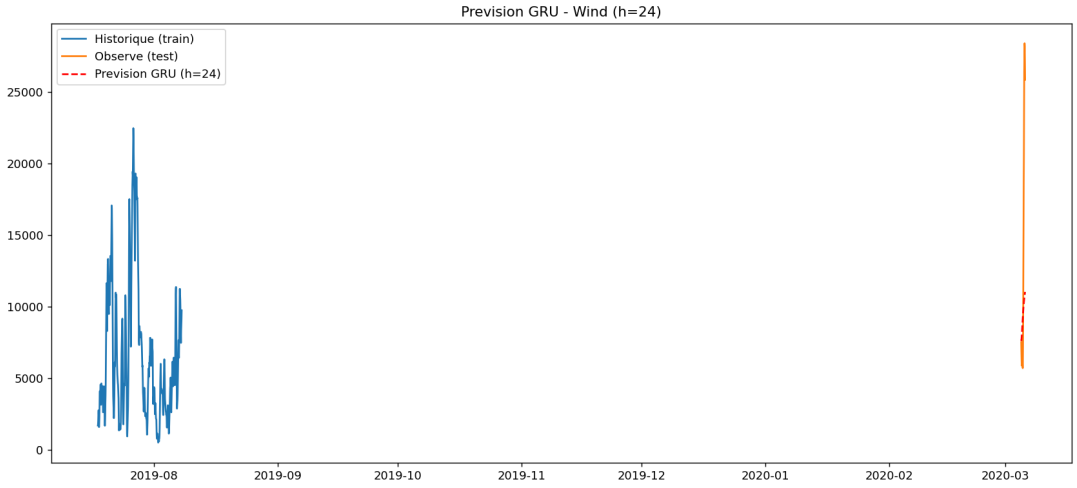


FIGURE 48 – Prévisions LSTM/GRU – `Wind`.

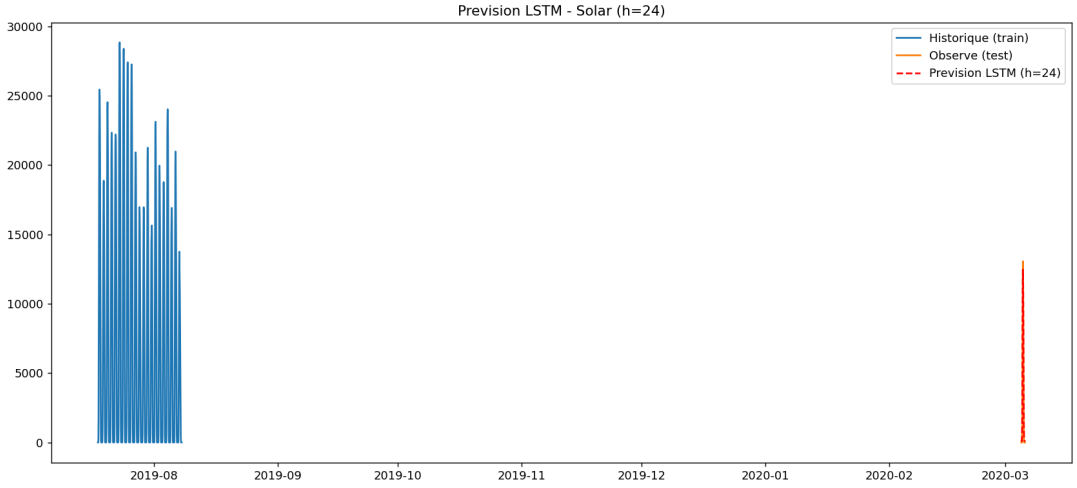


FIGURE 49 – Prévisions LSTM/GRU – `Solar`.

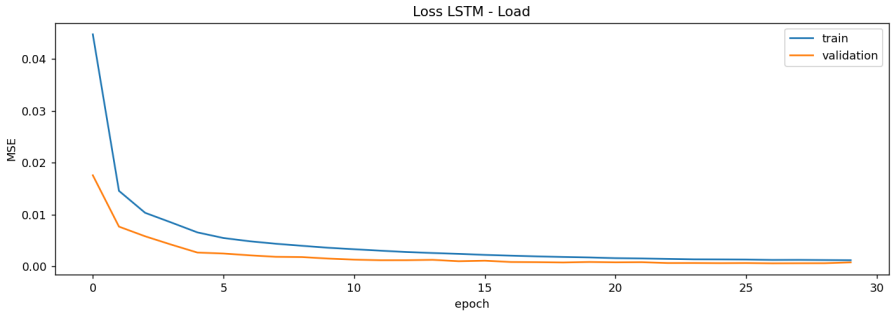


FIGURE 50 – Courbes de *loss* – `Load`.

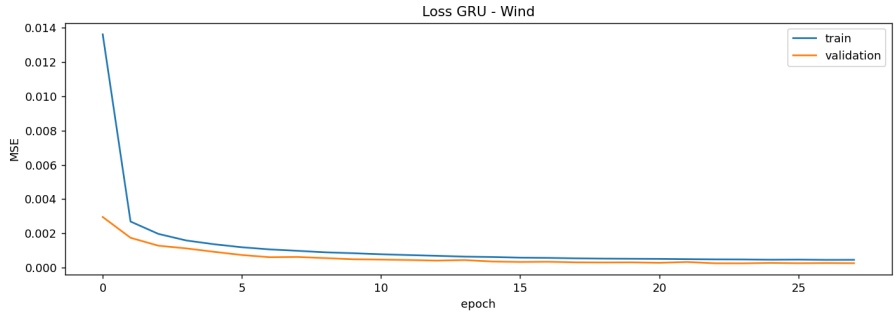


FIGURE 51 – Courbes de *loss* – `Wind`.

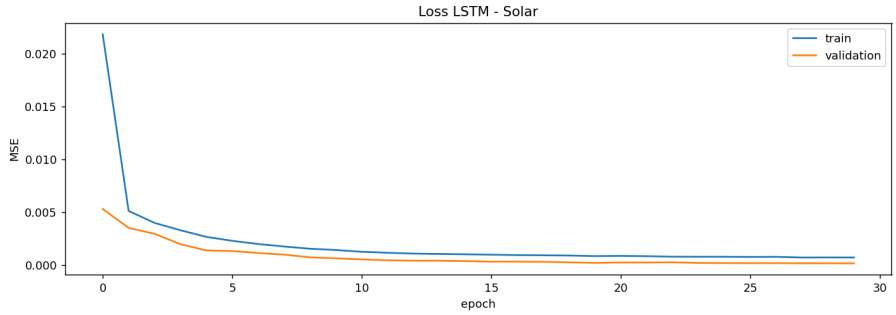


FIGURE 52 – Courbes de *loss* – `Solar`.

4 Évaluation comparative

4.1 Classement général (R vs Python vs LSTM/GRU)

Le classement agrégé `py_evaluation_ranking.csv` confronte, pour chaque couple (Variable, Horizon), les modèles R classiques, Python classiques et LSTM/GRU selon RMSE/MAE/MAPE. Le tableau 21 en extrait les meilleurs modèles par variable et par horizon.

TABLE 21 – Meilleurs modèles par variable et par horizon (extrait de `py_evaluation_ranking.csv`).

Variable	h	Meilleur modèle (RMSE le plus faible)	RMSE	MAPE (%)
`Load`	10	Hybride_SARIMA_LSTM (Python)	780,6	1,20
`Load`	24	Hybride_SARIMA_LSTM (Python)	970,7	1,35
`Load`	5040	Prophet (Python)	3 985,9	6,33
`Wind`	10	ARIMA_auto (R)	512,4	7,37
`Wind`	24	LSTM (Python)	7 870,1	42,78
`Wind`	5040	GRU (Python)	8 567,3	172,26
`Solar`	10	Hybride_SARIMA_LSTM (Python)	528,0	282,44
`Solar`	24	LSTM (Python)	579,0	6,07e12
`Solar`	5040	Prophet (Python)	5 020,4	8 127,28

La figure 53 synthétise ces RMSE. Les enseignements sont :

— à **court terme** ($h = 10$), un modèle **hybride SARIMA + LSTM** (Python) obtient la meilleure RMSE sur `Load` et `Solar` ; la transposition classique (`SARIMA_manuel`) reste très proche, avec des résultats **quasi identiques** en R et en Python (reproductibilité confirmée) ;
— à **l'horizon journalier** ($h = 24$), les modèles profonds (LSTM) prennent l'avantage sur `Wind` et `Solar`, tandis que l'hybride conserve la première place sur `Load` ;
— à **très long terme** ($h = 5\,040$), **Prophet** domine sur `Load` (RMSE divisée par 4 par rapport au LSTM) et `Solar`, et les réseaux récurrents (**GRU** pour la RMSE) s'imposent sur `Wind` ;
— `Solar` reste la série la plus difficile, en raison de sa nature intermittente, de ses valeurs nulles (MAPE ininterprétable) et du test débutant pendant la période COVID-19.

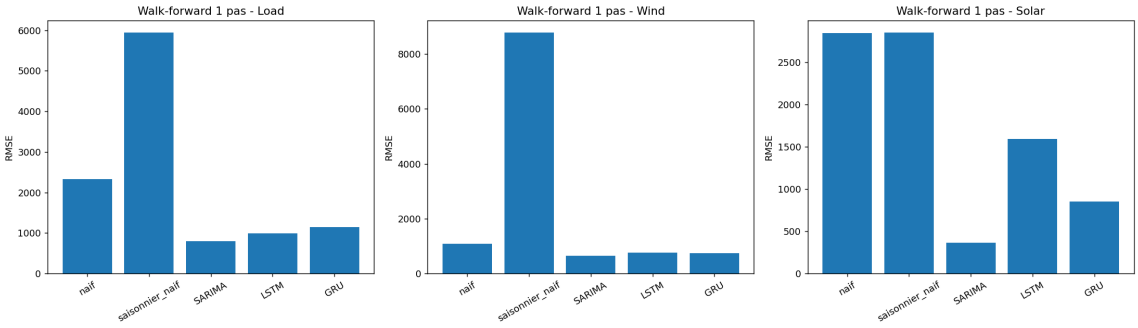


FIGURE 53 – Comparaison des RMSE par variable et par horizon.

4.2 Walk-forward à un pas

L'évaluation walk-forward à un pas confronte les baselines *naïve* et *saisonnière-naïve* (24 h) au SARIMA retenu, au LSTM et au GRU, sur les 5 040 h du test. Le tableau 22 montre que le **SARIMA** obtient les meilleures métriques pour les trois séries (`Load` : RMSE 797,1 contre 998,3 pour le LSTM ; `Solar` : 367,0 contre 856,0 pour le GRU). Les réseaux récurrents restent néanmoins nettement supérieurs aux modèles naïfs. Les prévisions sont archivées dans `results/forecasts/py_walkforward_*.csv`.

TABLE 22 – Métriques walk-forward à un pas. Source : `py_walkforward_metrics.csv`.

Variable	Modèle	MSE	RMSE	MAE
`Load`	naïf	5 420 103	2 328,1	1 807,0
`Load`	saisonnier naïf	35 376 448	5 947,8	3 889,6
`Load`	SARIMA	635 357	797,1	590,3
`Load`	LSTM	996 585	998,3	771,7
`Load`	GRU	1 307 527	1 143,5	875,7
`Wind`	naïf	1 187 705	1 089,8	782,6
`Wind`	saisonnier naïf	77 192 711	8 785,9	6 358,1
`Wind`	SARIMA	427 719	654,0	452,9
`Wind`	LSTM	577 189	759,7	552,9
`Wind`	GRU	544 219	737,7	520,4
`Solar`	naïf	8 114 702	2 848,6	1 889,3
`Solar`	saisonnier naïf	8 153 433	2 855,4	1 417,7
`Solar`	SARIMA	134 710	367,0	245,0
`Solar`	LSTM	2 549 469	1 596,7	1 344,4
`Solar`	GRU	732 792	856,0	659,0

4.3 Test de Diebold–Mariano

Le test de Diebold–Mariano est appliqué à **toutes les paires** de modèles du walk-forward sur les erreurs quadratiques (un pas), avec correction HLN et variance HAC (retard 1). Le tableau 23 en présente les comparaisons clés. Toutes les statistiques sont hautement significatives (p-valeurs $< 10^{-18}$ dans l'écrasante majorité des cas) : sans ambiguïté, le **SARIMA est statistiquement meilleur** que les naïfs, le LSTM et le GRU pour les trois séries. Entre réseaux, le **LSTM** l'emporte sur `Load` et le **GRU** sur `Wind` et `Solar`.

TABLE 23 – Test de Diebold–Mariano (extrait des paires du walk-forward). Source : `py_diebold_mariano.csv`.

Variable	A vs B	DM stat	p-valeur	Conclusion
`Load`	naïf vs SARIMA	+38,62	4,37e-286	SARIMA meilleur
`Load`	saisonnier naïf vs SARIMA	+34,60	1,56e-235	SARIMA meilleur
`Load`	SARIMA vs LSTM	−16,19	1,65e-57	SARIMA meilleur
`Load`	SARIMA vs GRU	−24,11	1,25e-121	SARIMA meilleur
`Load`	LSTM vs GRU	−12,07	4,17e-33	LSTM meilleur
`Wind`	naïf vs SARIMA	25,44	2,01e-134	SARIMA meilleur
`Wind`	saisonnier naïf vs SARIMA	35,92	9,97e-252	SARIMA meilleur
`Wind`	SARIMA vs LSTM	−14,63	1,69e-47	SARIMA meilleur
`Wind`	SARIMA vs GRU	−11,26	4,85e-29	SARIMA meilleur
`Wind`	LSTM vs GRU	8,87	1,03e-18	GRU meilleur
`Solar`	naïf vs SARIMA	44,27	0,00	SARIMA meilleur
`Solar`	saisonnier naïf vs SARIMA	21,60	5,05e-99	SARIMA meilleur
`Solar`	SARIMA vs LSTM	−63,20	0,00	SARIMA meilleur
`Solar`	SARIMA vs GRU	−31,18	2,55e-195	SARIMA meilleur
`Solar`	LSTM vs GRU	39,75	9,23e-301	GRU meilleur

Nuance importante. Ce résultat concerne la prévision **à un pas** (walk-forward). Il met en évidence la supériorité du SARIMA à un pas (filtre de Kalman mis à jour), qui ne contredit pas l'avantage des modèles profonds sur les *trajectoires récursives* multi-pas (cf. tableau 20), ni l'explosion du MAPE pour `Solar`. Le test DM entre SARIMA et LSTM sur les trajectoires $h > 1$ constitue une piste d'approfondissement (cf. section 6).

5 Interface interactive : dashboard Streamlit

Afin de restituer les résultats de façon exploratoire, un *dashboard* **Streamlit** a été développé (dossier `dashboard/`). Il se lance par la commande :

```
streamlit run dashboard/app.py
```

et lit directement les sorties des scripts R/Python (`results/figures/`, `results/tables/` et `results/forecasts/`). Il est composé d'une page d'accueil et de cinq pages accessibles via la barre latérale. Les captures d'écran ci-dessous (documentées dans `results/dashboard/`) illustrent chaque interface.

5.1 Vue d'ensemble

La page d'accueil affiche des indicateurs synthétiques (nombre de figures, de tableaux et de prévisions) et le *Top 8* des meilleurs RMSE par couple (Variable, Horizon), extrait de `py_evaluation_ranking.csv`.

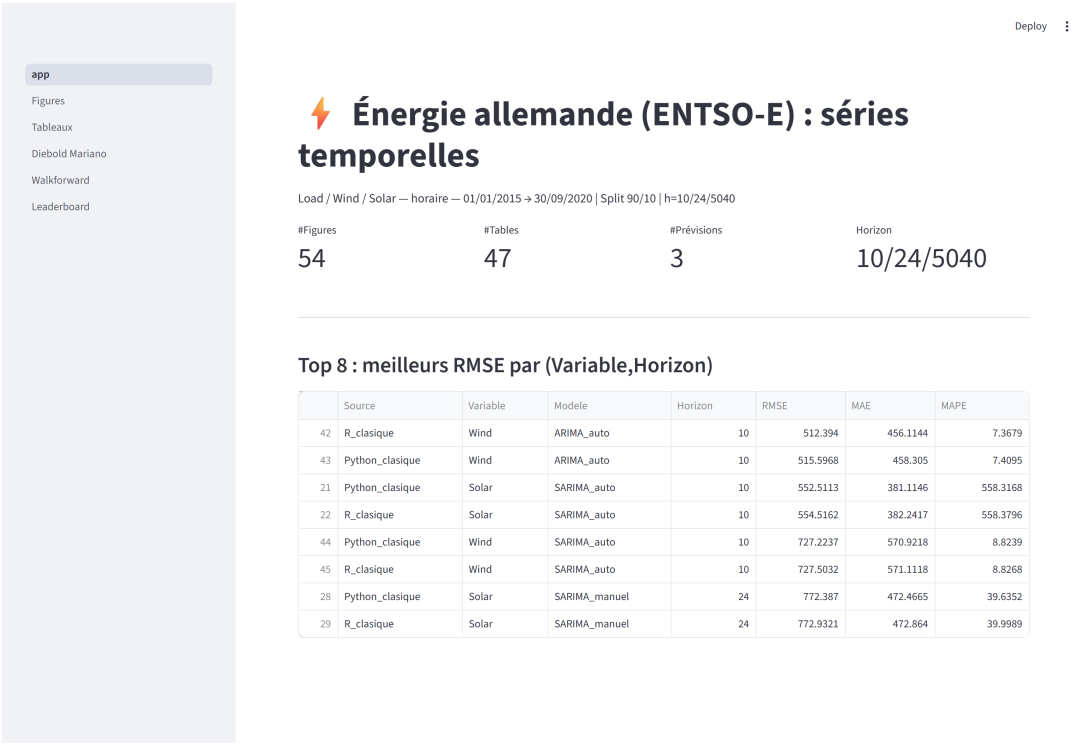


FIGURE 54 – Interface Streamlit — page « Vue d'ensemble ».

5.2 Page « Figures »

Cette page constitue une galerie de l'ensemble des figures générées (54 fichiers `*.png`) avec leur légende.

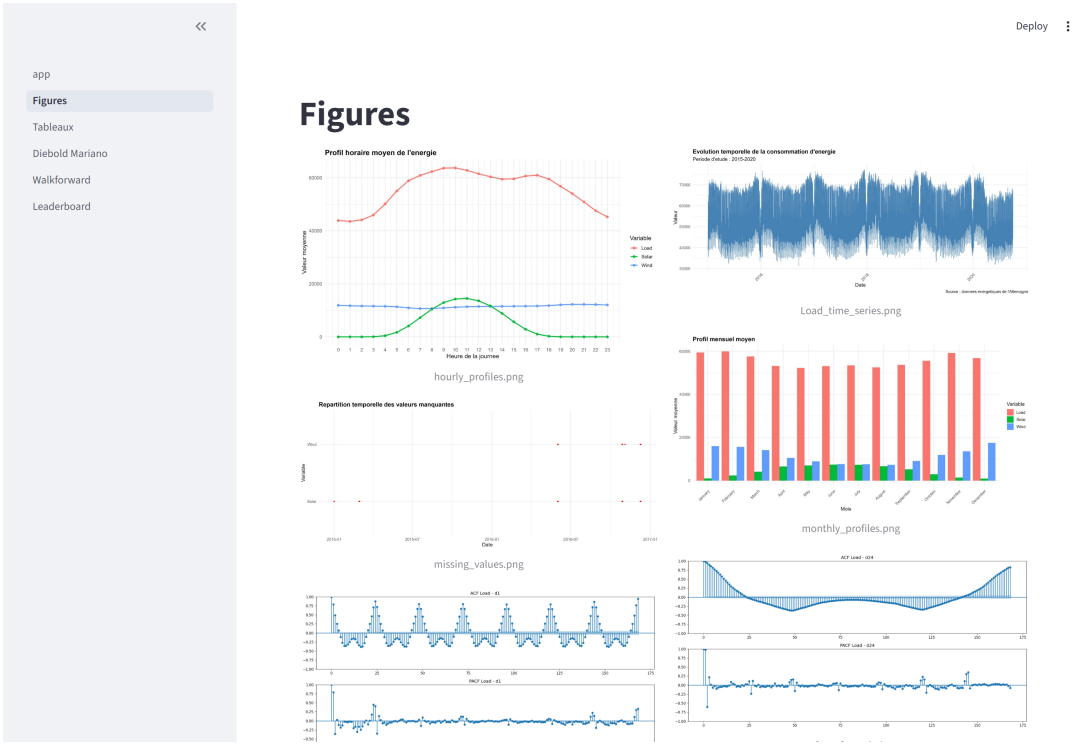


FIGURE 55 – Interface Streamlit — galerie « Figures ».

5.3 Page « Tableaux de résultats »

Un sélecteur latéral permet de parcourir les 47 tables CSV produites, et de visualiser n'importe quel tableau de résultats.

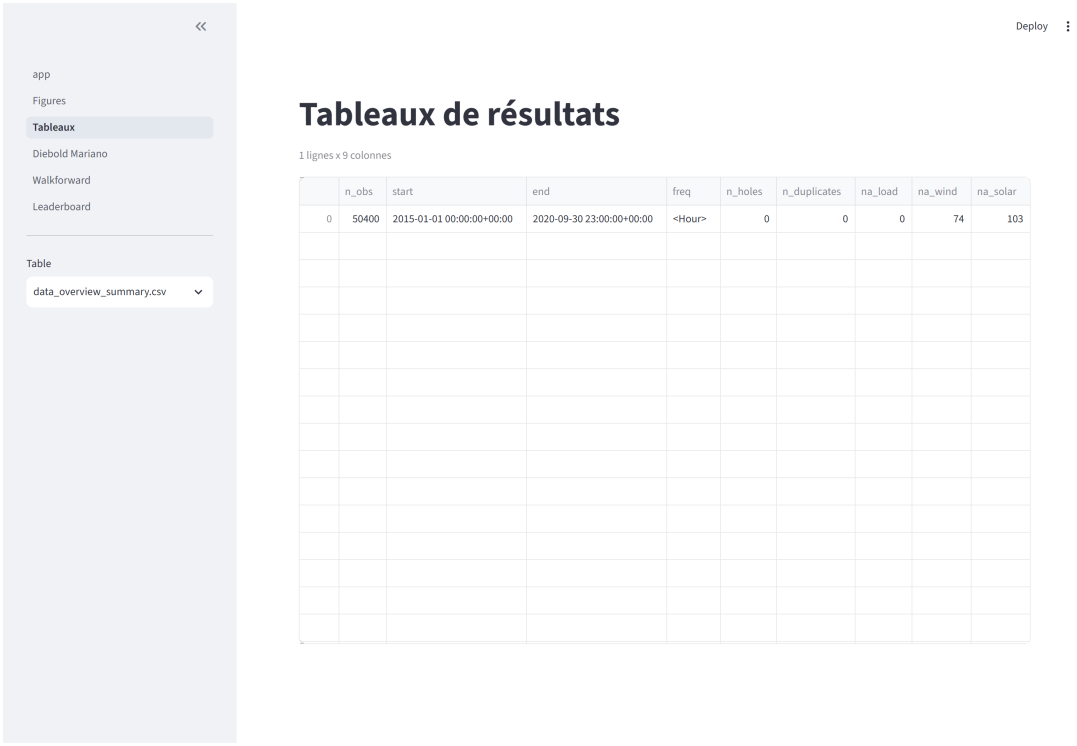


FIGURE 56 – Interface Streamlit — exploration des tableaux CSV.

5.4 Page « Diebold–Mariano »

Cette page présente le tableau du test de Diebold–Mariano (`py_diebold_mariano.csv`) comparant **toutes les paires** de modèles du walk-forward (naïfs, SARIMA, LSTM, GRU).



FIGURE 57 – Interface Streamlit — test de Diebold–Mariano.

5.5 Page « Prévisions walk-forward »

Un graphique interactif (Plotly) permet de sélectionner une variable et de comparer la série observée aux prévisions à un pas (SARIMA, LSTM, GRU, naïf, saisonnier naïf), avec une vue zoomée sur les 200 premiers points.



FIGURE 58 – Interface Streamlit — prévisions walk-forward.

5.6 Page « Leaderboard »

Enfin, cette page classe par RMSE les modèles (R, Python classique, LSTM/GRU, Prophet, hybride) pour une variable et un horizon choisis, sous forme de tableau et de diagramme en barres interactif.

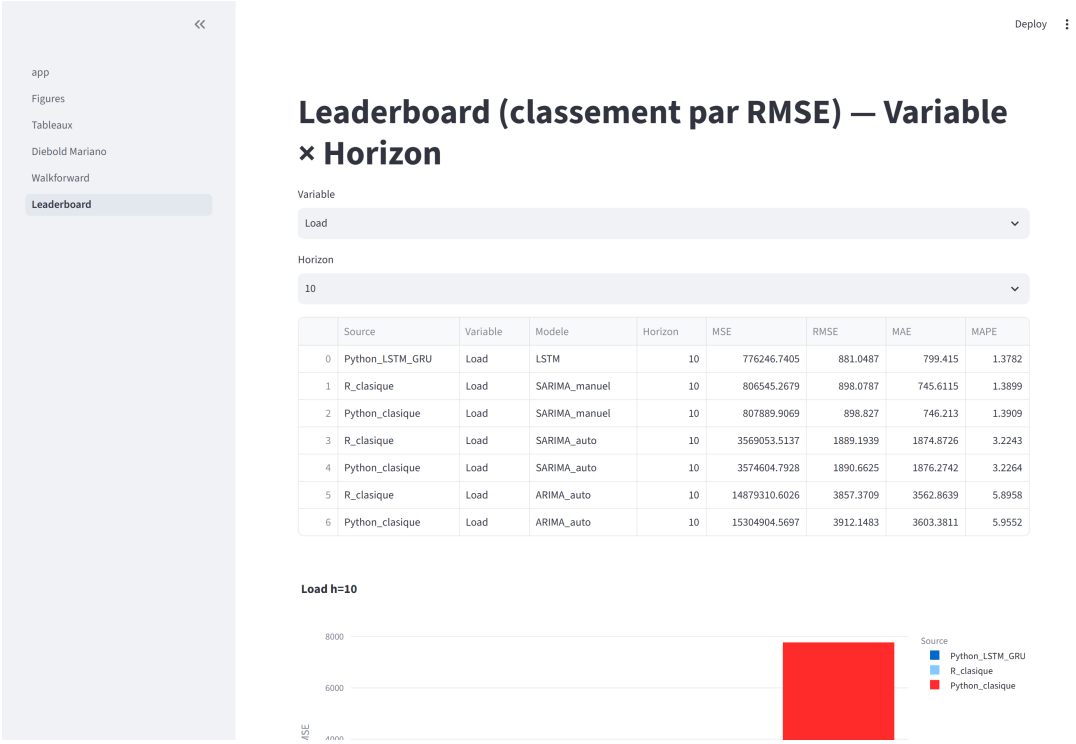


FIGURE 59 – Interface Streamlit — leaderboard par variable et horizon.

6 Conclusion

6.1 Bilan des résultats

Ce mini-projet a mis en œuvre, sur les trois séries énergétiques allemandes (`Load`, `Wind`, `Solar`), une chaîne complète d'analyse de séries temporelles, **duale R / Python**. Les principaux résultats sont les suivants.

— **Analyse exploratoire.** Les séries présentent une saisonnalité quotidienne ($m = 24$) et hebdomadaire forte, une asymétrie marquée pour `Wind`/`Solar` et une saisonnalité annuelle opposée (éolien hivernal, solaire estival). Les séries brutes sont non stationnaires ; la différenciation $d = 1$ les rend stationnaires (ADF et KPSS concordants).

— **ARIMA/SARIMA.** Les ordres retenus par AICc sont **identiques** en R et en Python (`SARIMA_manuel` pour `Load`/`Wind`, `SARIMA_auto` pour `Solar`). Les diagnostics rejettent l'absence d'autocorrélation, de non-normalité et d'effet ARCH, ce dernier point motivant le volet GARCH.

— **VAR / Granger / VECM.** L'ordre $p = 14$ est retenu par AIC. La causalité de Granger identifie une unique relation significative `Wind` $\rightarrow$ `Load`. La cointégration de Johansen donne $r = 2$, et le VECM produit des vecteurs β et des vitesses α **reproductibles** entre R et Python.

— **GARCH.** La volatilité des variations journalières est très persistante ($\approx 0{,}99$ pour `Wind`) ; `Solar` est non covariation-stationnaire en GARCH(1,1)/GARCH(2,1), seul l'EGARCH(1,1) restant stable. Les innovations de Student capturent les queues épaisses.

— **LSTM/GRU.** Les réseaux récurrents apportent un gain mesurable à très long horizon ($h = 5\,040$ sur `Load` : RMSE 7 593 contre 65 847 pour le SARIMA) et

surpassent nettement les naïfs en walk-forward un pas. À un pas, le **SARIMA** reste toutefois le meilleur modèle (test de Diebold–Mariano hautement significatif), ce qui conforte l'intérêt des approches hybrides.

— **Reproductibilité.** Les deux implémentations (R et Python) produisent des métriques quasi identiques (écarts $< 0{,}5\,\%$), validant la démarche de double codage.

6.2 Limites

1. **Horizon long.** À $h = 5\,040$, les prévisions récursives des modèles classiques divergent ; seule la comparaison inter-modèles reste informative.
2. **MAPE et `Solar`.** La proximité de zéro (nuit) rend le MAPE ininterprétable ; il doit être systématiquement complété par RMSE/MAE.
3. **Saisonnalité tronquée.** Seul $m = 24$ est modélisé explicitement ; la saisonnalité hebdomadaire ($m = 168$) et annuelle ne sont pas prises en compte par les modèles ARIMA/SARIMA, ce qui limite la qualité à moyen terme.
4. **Ordre VAR élevé.** $p = 14$ sur $\approx 1\,890$ jours d'apprentissage peut conduire à un sur-ajustement ; les critères HQ/SC suggèrent un ordre plus faible.
5. **Période de test COVID.** Le test débute le 5 mars 2020, à l'entrée de la crise sanitaire : la rupture de régime affecte nécessairement les performances.
6. **Monovariable pour le LSTM.** Les réseaux sont entraînés série par série, sans exploiter l'information croisée (Wind/Solar/Load), pourtant mise en évidence par le VECM.

6.3 Perspectives

1. Intégrer des **régresseurs de Fourier** (saisonnalités 24/168) ou un SARIMA à $m = 168$ sur fenêtres plus courtes.
2. Passer à des LSTM/GRU **multivariés** (entrées conjointes des trois séries) et ajouter des variables exogènes (température, vent, irradiance).
3. Conduire le test de **Diebold–Mariano entre SARIMA et LSTM** sur les trajectoires $h > 1$, et non seulement en un pas.
4. Étudier des modèles de volatilité multivariés (DCC-GARCH) pour la dépendance conditionnelle entre séries.
5. Produire des **intervalles de prévision** calibrés (prévision probabiliste) plutôt que des points.
6. Déployer l'ensemble dans un *dashboard* interactif (Streamlit, déjà présent dans `dashboard/`) pour la vulgarisation.

En définitive, le socle classique (ARIMA, VAR/VECM, GARCH) et son extension profonde (LSTM/GRU) ont été implémentés de façon cohérente et reproductible, et comparés rigoureusement. Les résultats confirment l'intérêt des approches hybrides : modèles classiques pour les horizons courts et interprétables, modèles profonds pour les horizons longs, l'ensemble devant être complété par une modélisation explicite des saisonnalités et des relations multivariées.

7 Annexes

7.1 Structure du projet et reproductibilité

L'ensemble du travail est contenu dans le dépôt `TimeSeries_Project` :

- `R/` : six scripts séquentiels — `01_data_preparation.R`, `02_EDA.R`, `03_diagnostics.R`, `04_ARIMA_SARIMA.R`, `05_VAR_VECM.R`, `06_GARCH.R` ;
- `Python/` : transposition (`arima_var.py`, `arima_intervals.py`, `garch.py`, `lstm_gru.py`, `prophet_model.py`, `hybrid_arima_lstm.py`, `evaluation.py`) ;
- `data/processed/` : données préparées ;
- `results/tables/`, `results/figures/`, `results/forecasts/`, `results/models/` : sorties (préfixes `R_` et `py_`) ;
- `rapport/` : le présent rapport LaTeX ;
- `dashboard/` : prototype Streamlit ;
- `notebooks/` : `analyse_complete.Rmd` et `analyse_complete.ipynb` (EDA) ;
- `notebooks/analyse_complete_full.ipynb` : notebook **bout-en-bout** couvrant les dix étapes du pipeline (données, EDA, stationnarité, ARIMA/SARIMA, GARCH, VAR/VECM, LSTM/GRU, Prophet et hybride, évaluation, volet IA).

Toutes les métriques et figures du rapport sont régénérables en exécutant les scripts dans l'ordre (voir le `README.md` de la racine).

7.2 Tableaux de synthèse complémentaires

TABLE 24 – Statistiques descriptives (version R). Source : `descriptive_statistics.csv`.

Variable	n	NA	Moyenne	Médiane	Min	Max
`Load`	50 400	0	55 492,5	55 092	31 307	77 549
`Wind`	50 326	74	11 552,2	9 015	135	46 064
`Solar`	50 297	103	4 566,0	173	0	32 947

TABLE 25 – Profil horaire moyen (MW). Source : `hourly_summary.csv`.

Heure	`Load`	`Wind`	`Solar`
0	43 882	11 884	0,01
1	43 553	11 737	0,01
2	44 134	11 640	0,31
3	45 950	11 589	41,67
4	50 132	11 537	426,92
5	55 042	11 337	1 688,08
6	58 898	10 927	4 081,74
7	60 921	10 670	7 253,83
8	62 353	10 676	10 471,87
9	63 641	10 914	12 925,39
10	63 734	11 171	14 278,53
11	62 801	11 359	14 482,78
12	61 518	11 451	13 595,15

Heure	Load	Wind	Solar
13	60 384	11 494	11 661,40
14	59 499	11 515	8 850,42
15	59 599	11 556	5 666,05
16	60 663	11 588	2 868,91
17	60 975	11 635	1 039,00
18	59 545	11 783	226,68
19	56 794	12 080	12,27
20	54 040	12 258	0,87
21	50 916	12 240	0,86
22	47 596	12 178	0,01
23	45 251	12 037	0,01

TABLE 26 – Profil hebdomadaire moyen (MW). Source : `weekly_summary.csv`.

Jour	Load	Wind	Solar
Lundi	57 523	11 492	4 557
Mardi	59 241	11 737	4 513
Mercredi	59 455	11 672	4 665
Jeudi	58 964	11 337	4 575
Vendredi	57 742	10 957	4 561
Samedi	49 619	11 777	4 517
Dimanche	45 902	11 892	4 575

TABLE 27 – Profil mensuel moyen (MW). Source : `monthly_summary.csv`.

Mois	Load	Wind	Solar
Janvier	59 446	16 029	1 029
Février	59 975	15 656	2 397
Mars	57 606	14 185	4 114
Avril	53 209	10 571	6 552
Mai	52 285	8 964	7 039
Juin	53 111	7 704	7 461
Juillet	53 453	7 608	7 378
Août	52 566	7 340	6 683
Septembre	53 705	9 134	5 270
Octobre	55 621	11 911	2 947
Novembre	59 232	13 593	1 446
Décembre	56 849	17 515	967

TABLE 28 – Évolution annuelle moyenne (MW). Source : `yearly_summary.csv`.

Année	Load	Wind	Solar
2015	54 737	8 810	3 986
2016	55 441	8 718	3 946
2017	56 178	11 720	4 096
2018	56 952	12 393	4 707
2019	55 990	14 133	4 785
2020	53 048	14 178	6 304

TABLE 29 – Métriques ARIMA/SARIMA (Python) — confirmation des valeurs R. Source : `py_arima_metrics.csv`.

Variable	Modèle	h	MSE	RMSE	MAE	MAPE (%)
Load	SARIMA_manuel	10	807 890	898,8	746,2	1,39
Load	SARIMA_manuel	24	1 143 498	1 069,3	874,3	1,48
Load	SARIMA_manuel	5040	4,34e9	65 852	59 496	121,82
Load	ARIMA_auto	10	15 304 905	3 912,1	3 603,4	5,96
Load	ARIMA_auto	24	26 822 868	5 179,1	4 634,8	7,28
Load	ARIMA_auto	5040	1,76e8	13 269	10 794	24,56
Load	SARIMA_auto	10	3 574 605	1 890,7	1 876,3	3,23
Load	SARIMA_auto	24	2 819 949	1 679,3	1 463,3	2,41
Load	SARIMA_auto	5040	4,18e10	204 474	179 830	365,40
Wind	SARIMA_manuel	10	1 080 974	1 039,7	947,1	15,05
Wind	SARIMA_manuel	24	1,60e8	12 662	9 065	46,35
Wind	SARIMA_manuel	5040	3,48e10	186 502	163 653	3 573,45
Wind	ARIMA_auto	10	265 840	515,6	458,3	7,41
Wind	ARIMA_auto	24	1,40e8	11 828	8 043	37,53
Wind	ARIMA_auto	5040	9,17e7	9 574	6 777	91,81
Wind	SARIMA_auto	10	528 854	727,2	570,9	8,82
Wind	SARIMA_auto	24	1,70e8	13 021	9 029	43,44
Wind	SARIMA_auto	5040	1,20e8	10 964	7 703	71,79
Solar	SARIMA_manuel	10	601 922	775,8	446,9	38,97
Solar	SARIMA_manuel	24	596 582	772,4	472,5	39,64
Solar	SARIMA_manuel	5040	5,37e7	7 330	4 656	373,74
Solar	ARIMA_auto	10	23 254 924	4 822,3	2 570,5	90,50
Solar	ARIMA_auto	24	31 937 475	5 651,3	3 221,8	96,16
Solar	ARIMA_auto	5040	1,44e8	12 020	7 606	101,04
Solar	SARIMA_auto	10	305 269	552,5	381,1	558,32
Solar	SARIMA_auto	24	700 494	837,0	585,5	1 428,24
Solar	SARIMA_auto	5040	5,97e7	7 727	6 373	24 073,80

7.3 Inventaire des figures

Toutes les figures sont dans `results/figures/`. Le tableau 30 en donne l'inventaire complet.

TABLE 30 – Inventaire des figures du projet.

Fichier	Script	Contenu
`Load_time_series.png`	R 02	Série temporelle de la charge
`Wind_time_series.png`	R 02	Série temporelle éolienne
`Solar_time_series.png`	R 02	Série temporelle solaire
`hourly_profiles.png`	R 02	Profil horaire moyen
`weekly_profiles.png`	R 02	Profil hebdomadaire moyen
`monthly_profiles.png`	R 02	Profil mensuel moyen
`yearly_profiles.png`	R 02	Évolution annuelle
`missing_values.png`	R 02	Valeurs manquantes (R)
`R_acf_pacf_Load_raw.png`	R 03	ACF/PACF Load brute
`R_acf_pacf_Load_d1.png`	R 03	ACF/PACF Load $d1$

Fichier	Script	Contenu
R_acf_pacf_Wind_raw.png	R 03	ACF/PACF Wind brute
R_acf_pacf_Wind_d1.png	R 03	ACF/PACF Wind $d1$
R_acf_pacf_Solar_raw.png	R 03	ACF/PACF Solar brute
R_acf_pacf_Solar_d1.png	R 03	ACF/PACF Solar $d1$
R_resid_{Load,Wind,Solar}.png	R 04	Diagnostics résidus
R_prev_{Load,Wind,Solar}.png	R 04	Prévisions $h = 24$
R_var_irf_load.png	R 05	Réponse impulsionnelle Load
R_var_fevd_load.png	R 05	Décomposition variance Load
R_garch_{Load,Wind,Solar}.png	R 06	Volatilité conditionnelle
py_ts_overview.png	py	Vue d'ensemble
py_seasonal_profiles.png	py	Profils saisonniers
py_stl_load_daily.png	py	STL journalier Load
py_stl_load_weekly.png	py	STL hebdomadaire Load
py_missing.png	py	Valeurs manquantes
py_outliers_load.png	py	Outliers Load
py_acf_pacf_Load_raw.png	py	ACF/PACF Load brute
py_acf_pacf_Load_d1.png	py	ACF/PACF Load $d1$
py_acf_pacf_Load_d24.png	py	ACF/PACF Load $d24$
py_acf_pacf_Wind_raw.png	py	ACF/PACF Wind brute
py_acf_pacf_Solar_raw.png	py	ACF/PACF Solar brute
py_resid_{Load,Wind,Solar}.png	py	Diagnostics résidus
py_prev_{Load,Wind,Solar}.png	py	Prévisions
py_var_irf_load.png	py	Réponse impulsionnelle Load
py_var_fevd_load.png	py	Décomposition variance Load
py_garch_{Load,Wind,Solar}.png	py	Volatilité conditionnelle
py_lstm_gru_forecast_{...}.png	py	Prévisions LSTM/GRU
py_lstm_gru_loss_{...}.png	py	Courbes de loss
py_evaluation_rmse.png	py	RMSE comparés

7.4 Inventaire des tableaux

Les 47 fichiers CSV de `results/tables/` se répartissent en :

— **Données/EDA** : descriptive_statistics.csv, descriptive_statistics_py.csv, energy_means.csv, hourly_summary.csv, weekly_summary.csv, monthly_summary.csv, yearly_summary.csv, profiles_{hour,month,week,year}_py.csv, missing_values.csv, missing_dates.csv, outliers_summary.csv, data_overview_summary.csv, stationarity_te R_stationarity_tests.csv ;

— **ARIMA/SARIMA** : {R,py}_arima_model_comparison.csv, {R,py}_arima_diagnostics.cs {R,py}_arima_metrics.csv ;

— **VAR/VECM** : {R,py}_var_order.csv, {R,py}_granger.csv, {R,py}_johansen.csv, {R,py}_vecm.csv, {R,py}_vecm_alpha.csv, {R,py}_var_diagnostics.csv, {R,py}_var_fevd

— **GARCH** : {R,py}_garch_coefficients.csv, {R,py}_garch_persistence.csv, {R,py}_garch_diagnostics.csv ;

— **LSTM/GRU et évaluation** : py_lstm_gru_metrics.csv, py_lstm_gru_cv.csv, py_evaluation_ranking.csv, py_walkforward_metrics.csv, py_diebold_mariano.csv, py_model_comparison.csv ;

— **Prévisions** : results/forecasts/ py_walkforward_{Load,Wind,Solar}.csv.

7.5 Volet IA générative

Le volet « analyse assistée par IA » a été conduit selon un **protocole manuel, sans clé API** (documenté dans `results/llm/README.md`) : génération de résumés factuels depuis les tables CSV, interrogation hors ligne d'un assistant, puis archivage des échanges. Trois échanges sont archivés dans `results/llm/echanges/` :

- `2026-10-11_analyse_sarima_lstm.md` : hiérarchie SARIMA vs LSTM à court et long terme ;
- `2026-10-12_interpretation_var_vecm_garch.md` : lecture de l'ordre VAR, de la causalité de Granger (Wind→Load, $p = 0{,}0022$), de la cointégration ($r = 2$) et de la persistance GARCH (Wind 0,9905, demi-vie 72,7 h) ;
- `2026-10-12_hierarchie_modeles_recommandations.md` : hiérarchie par horizon, opposition walk-forward 1 pas *vs* trajectoire depuis une origine fixe, recommandations.

Conformément aux contraintes anti-hallucination, chaque réponse a été **relue critiquement** (sections « Relecture critique » des fichiers) : les chiffres proviennent exclusivement de `results/tables/`, les affirmations non vérifiables ont été rejetées, et des éléments absents de la réponse du modèle (par ex. le biais COVID de la période de test) ont été ajoutés par l'étudiant. **Aucun chiffre** issu du modèle de langage n'a été reporté sans vérification dans `results/tables/`.

Références

ENTSO-E Transparency Platform [Consulté en 2026]. (2026). https://transparency.entsoe.eu/